

Audio-Laya: การเชื่อมคุณลักษณะเสียงเข้ากับโมเดลตัดสินใจที่ผ่านการ ฝึกล่วงหน้าด้วยชั้นแปลงมิติ

รายงานทางเทคนิคว่าด้วยการคัดกรองสายโทรศัพท์ การจัดแนวความหมายระหว่างเสียงกับข้อความ และ
การประเมินการถ่ายโอนงาน

ธนบดี นามมงคล

ORCID: [0009-0004-9410-9839](https://orcid.org/0009-0004-9410-9839)

ฉบับ 1.2 • กันยายน 2026

บทคัดย่อ

รายงานนี้ประเมินแนวทางนำข้อมูลเสียงมาใช้กับโมเดลตัดสินใจที่มีอยู่ โดยตรงตัวเข้ารหัสเสียงที่ผ่านการฝึกล่วงหน้าไว้ แล้วฝึกชั้นแปลงมิติ (projector) เพื่อเชื่อมคุณลักษณะเสียงกับโมเดล Laya ซึ่งตัดสินใจจากข้อความ วิธี A ซึ่งฝึกเฉพาะชั้นแปลงมิติได้ค่า Macro F1 เท่ากับ 99.6% ส่วนวิธี B ซึ่งปรับทั้งชั้นแปลงมิติและส่วนหัวตัดสินใจได้ 100.0% จากชุดทดสอบภายใน 282 สาย ขณะที่วิธี C ซึ่งใช้ Whisper ถอดเสียงก่อนส่งข้อความให้ Laya ได้ 89.2% อย่างไรก็ตาม ชุดทดสอบนี้กำหนดสาย spam จาก FTC และสาย legitimate จาก Harper ทั้งหมด จึงแยกผลของป้ายกำกับออกจากผลของแหล่งข้อมูลไม่ได้ และยังใช้ยืนยันประสิทธิภาพการตรวจจับสายหลอกลวงจากแหล่งเสียงใหม่ไม่ได้

การประเมินกับ MinDS-14 พบว่าวิธีที่รับเสียงโดยตรงยังถ่ายโอนความสามารถไปสู่งานจำแนกเจตนาของผู้ใช้บริการได้ไม่ดี ส่วนผลบนชุดเสียงสังเคราะห์ 40 คลิปสำหรับจำแนกความเร่งด่วนยังแปรผัน การฝึกเพื่อจัดแนวความหมายระหว่างเสียงกับข้อความช่วยให้ค้นหาข้อความถอดเสียงที่สัมพันธ์กับเสียงได้ดีขึ้น แต่ไม่ได้ทำให้การจำแนกงานใหม่มีประสิทธิภาพสูงขึ้นอย่างสม่ำเสมอ การฝึกสามรอบที่จับเวลาไว้ใช้เวลา 492.11 วินาทีบน AMD Radeon RX 9070 XT โดยรวมแล้ว ผลการทดลองเป็นหลักฐานเบื้องต้นของการปรับโมเดลให้เชี่ยวชาญเฉพาะงาน มีข้อหลักฐานว่าโมเดลเข้าใจเสียงได้ครอบคลุมทุกงาน จำนวนพารามิเตอร์ที่ปรับมีน้อยเมื่อเทียบกับโมเดลฐานที่ตรงไว้ แต่ไม่ได้สะท้อนจำนวนพารามิเตอร์ หน่วยความจำ หรือภาระการประมวลผลทั้งหมดของระบบ

คำสำคัญ: การจำแนกเสียงพูด; การปรับโมเดลตามรูปแบบข้อมูล; ชั้นแปลงมิติ; ตัวเข้ารหัสที่ตรงพารามิเตอร์; โมเดลตัดสินใจแบบกำหนดชนิดผลลัพธ์; การคัดกรองสายโทรศัพท์; การจัดแนวความหมายระหว่างเสียงกับข้อความ

สารบัญ

1	บทนำ	1
1.1	สรุปสำหรับผู้อ่านทั่วไป	1
1.2	คำถามวิจัยและขอบเขต	1
2	พื้นฐานและสถาปัตยกรรมระบบ	3
2.1	องค์ประกอบของแบบจำลอง	3
3	ระเบียบวิธีวิจัยและการประเมินผล	4
3.1	การฝึกและการจัดแนวความหมาย	4
3.2	ข้อมูลและวิธีประเมิน	4
3.2.1	การจำแนกสายโทรศัพท์	4
3.2.2	ชุดข้อมูลถ่ายโอน	5
3.2.3	นิยามตัวชี้วัด	5
3.3	แนวทางการทำซ้ำและสถานะ	5
3.3.1	ที่มาของข้อมูลและการแบ่งชุด	5
3.3.2	แบบจำลองและค่าการฝึก	6
3.3.3	สภาพแวดล้อม คำสั่ง และผลลัพธ์	6
3.3.4	สรุปตามรายการตรวจสอบ	8
4	ผลการทดลองและอภิปรายผล	10
4.1	ผลเชิงปริมาณ	10
4.1.1	ผลการจำแนกสายไม่พึงประสงค์และสายปกติ	10
4.1.2	ผลการถ่ายโอนงานโดยไม่ปรับแต่งด้วยข้อมูลเป้าหมาย	11
4.1.3	ผลของการจัดแนวความหมายระหว่างเสียงกับข้อความ	11
4.2	การตีความผล	12
5	ข้อจำกัด การใช้อย่างรับผิดชอบ และบทสรุป	14
5.1	ข้อจำกัดและการใช้อย่างรับผิดชอบ	14

5.2	สรุป	15
	เอกสารอ้างอิง	16

บทที่ 1

บทนำ

1.1 สรุปสำหรับผู้อ่านทั่วไป

โมเดลปัญญาประดิษฐ์แบบใช้งานทั่วไปมักออกแบบให้รองรับงานหลายประเภทด้วยระบบเดียว การศึกษานี้ประเมินแนวทางแบบแยกส่วน โดยนำตัวเข้ารหัสเสียงที่ผ่านการฝึกล่วงหน้ามาใช้ซ้ำ และฝึกชั้นแปลงมิติขนาดเล็กเพื่อเชื่อมคุณลักษณะเสียงเข้ากับโมเดลตัดสินใจที่มีอยู่ วิธีนี้มุ่งให้ระบบตัดสินใจในงานเฉพาะด้าน เช่น จำแนกสายไม่พึงประสงค์ (spam) และสายปกติ (legitimate)


ผลการทดลองแสดงว่าระบบทำคะแนนได้สูงบนชุดทดสอบภายในชุดหนึ่ง แต่ยังไม่ยืนยันว่าสามารถตรวจจับสายหลอกลวงจากแหล่งเสียงอื่น หรือนำไปใช้กับงานเสียงประเภทอื่น ภาพ และข้อมูลจากเซนเซอร์ได้ ชุดทดสอบหลักมีความปะปนระหว่างแหล่งข้อมูลกับป้ายกำกับอย่างสมบูรณ์ ขณะที่ชุดประเมินการถ่ายโอนงานก็มีข้อจำกัดหลายประการ ดังนั้น หลักฐานที่มีจึงรองรับเพียงความเป็นไปได้ของแนวทางนี้ในงานเฉพาะด้าน ยังไม่เพียงพอที่จะสรุปว่าเป็นโมเดลที่ใช้งานได้ทั่วไป

1.2 คำถามวิจัยและขอบเขต

การศึกษานี้ตรวจสอบว่าคุณลักษณะจากตัวเข้ารหัสเสียงที่ตรงพารามิเตอร์ไว้สามารถนำไปใช้กับโมเดลตัดสินใจที่ผ่านการฝึกล่วงหน้าได้หรือไม่ โดยฝึกชั้นแปลงมิติเป็นตัวเชื่อม และในบางวิธีปรับส่วนหัวตัดสินใจเพิ่มเติม การศึกษานี้ไม่ได้พัฒนาแบบจำลองรู้จำเสียงพูดใหม่ และไม่ได้ปรับพารามิเตอร์ของตัวเข้ารหัส Whisper

แนวคิดหลักคือ:

แทนที่จะใช้โมเดลเดียวกับทุกงาน อาจนำตัวเข้ารหัสที่ผ่านการฝึกล่วงหน้ามาปรับใช้กับระบบตัดสินใจเฉพาะด้าน โดยฝึกชั้นแปลงมิติขนาดเล็กเท่าที่จำเป็น



ในเส้นทางที่รับเสียงโดยตรง ระบบไม่สร้างและไม่ใช้ข้อความถอดเสียงในขั้นอนุมาน ส่วนการทดลองจัดแนวความหมายระหว่างเสียงกับข้อความใช้ข้อความถอดเสียงจากข้อมูลต้นทางเป็นสัญญาณกำกับระหว่างฝึกเท่านั้น การศึกษานี้ประเมินเฉพาะเส้นทางข้อมูลเสียงและข้อความ ยังไม่ได้ทดสอบภาพ วิดีโอ หรือข้อมูลจากเซนเซอร์

บทที่ 2

พื้นฐานและสถาปัตยกรรมระบบ

2.1 องค์ประกอบของแบบจำลอง

การทดลองใช้แบบจำลองสองส่วนหลัก ได้แก่:

- ตัวเข้ารหัสเสียง Whisper-small.en: [openai/whisper-small.en](https://openai.com/whisper-small.en)
- โมเดลตัดสั่นใจ Laya: [convaiinnovations/laya](https://convaiinnovations.com/laya) [1, 2]

ขั้นแปลงมิติรับคุณลักษณะเสียงขนาด 768 มิติ แล้วแปลงเป็นตัวแทนขนาด 1024 มิติให้ตรงกับรูปแบบข้อมูลเข้าที่ Laya รองรับ น้ำหนัก Laya ที่ใช้ในการทดลองต่อยอดจาก ModernBERT-large ซึ่งผ่านการฝึกล่วงหน้า จึงเป็นโมเดลตัดสั่นใจจากข้อความ มีใช้โมเดลเสียงที่ฝึกขึ้นใหม่

ตารางที่ 2.1: ส่วนที่ปรับในแต่ละวิธี จำนวนพารามิเตอร์นับเฉพาะพารามิเตอร์ที่ฝึก มีใช้ขนาดรวมของแบบจำลองที่โหลดขณะอนุมาน

วิธี	ส่วนที่ปรับระหว่างฝึก	จำนวนพารามิเตอร์ที่ปรับ
A: ฝึกเฉพาะขั้นแปลงมิติ	ฝึกขั้นแปลงมิติ; ตรึงส่วนตัดสั่นใจของ Laya	1,838,592
B: ปรับขั้นแปลงมิติและส่วนหัวตัดสั่นใจ	ขั้นแปลงมิติ, เวกเตอร์แทนประเภทผลลัพธ์ (type embedding), โครงข่าย Transformer สำหรับตัดสั่นใจ และตัวให้คะแนนตัวเลือกของ Laya	28,086,785
C: ASR → Laya	ไม่ปรับแต่งกับงานปลายทาง; Whisper ถอดเสียงเป็นข้อความก่อนส่งให้ Laya รุ่นมาตรฐาน	0
A + จัดแนวความหมาย	ฝึกเฉพาะขั้นแปลงมิติ; เพิ่มฟังก์ชันจัดแนวเสียงกับข้อความระหว่างฝึก	1,838,592

เอกสารกำกับโมเดล (model card) ที่เผยแพร่ระบุว่า Laya มีพารามิเตอร์ 421 ล้านตัว ดังนั้นคำว่า “ขนาดเล็ก” ในรายงานนี้หมายถึงจำนวนพารามิเตอร์ที่ปรับและต้นทุนการฝึกในการทดลองที่จับเวลาไว้เท่านั้น ไม่ได้หมายถึงขนาดรวม หน่วยความจำหรือภาระการประมวลผลขณะใช้งานจริง ทั้ง Whisper และ Laya ยังต้องโหลดเข้าสู่ระบบ เอกสารกำกับโมเดลของ Laya ระบุว่าโมเดลนี้รองรับงานจำแนกข้อความและตรวจจับ spam บางประเภท การทดลองนี้จึงประเมินการเชื่อมข้อมูลเสียงเข้ากับความสามารถตัดสั่นใจที่มีอยู่แล้ว มีใช้การฝึกให้โมเดลเรียนรู้แนวคิดเรื่อง spam จากศูนย์ [2]

บทที่ 3

ระเบียบวิธีวิจัยและการประเมินผล

3.1 การฝึกและการจัดแนวความหมาย

งานที่ใช้การเรียนรู้แบบมีผู้สอนคือการจำแนกเสียงสายโทรศัพท์เป็น spam หรือ legitimate วิธี A และ B รับเสียงโดยตรง ส่วนวิธี C ใช้ข้อความ โดย Whisper ทำหน้าที่เป็นระบบรู้จำเสียงพูดอัตโนมัติ (ASR) และถอดเสียงก่อนส่งข้อความให้ Laya รุ่นมาตรฐาน ทั้งสองวิธีจึงรับข้อมูลคนละชนิด ไม่ใช่การเปรียบเทียบแบบจำลองเสียงกับแบบจำลองข้อความภายใต้เงื่อนไขเดียวกัน

การทดลองจัดแนวความหมายระหว่างเสียงกับข้อความใช้ข้อมูลเสียงประมาณ 22.91 ชั่วโมงจากชุดฝึกของ FTC และ Harper ครอบคลุมสายต้นฉบับ 1,926 สาย ช่วงเสียงที่จับคู่กับข้อความ 3,520 ช่วง และข้อความถอดเสียงที่ไม่ซ้ำกัน 3,028 รายการ โดยฝึกขึ้นแปลงมิติด้วยฟังก์ชันสูญเสีย:

$$\mathcal{L} = \mathcal{L}_{\text{spam}} + 0.05 \mathcal{L}_{\text{InfoNCE}}, \quad \tau = 0.07, \quad (3.1)$$

พจน์ InfoNCE เป็นฟังก์ชันสูญเสียแบบเปรียบเทียบ (contrastive loss) ซึ่งช่วยให้เวกเตอร์แทนเสียงอยู่ใกล้กับเวกเตอร์แทนข้อความถอดเสียงที่เป็นคู่กัน ในการฝึกนี้ตรึงตัวเข้ารหัสของ Whisper ตัวเข้ารหัสข้อความของ Laya และส่วนหัวตัดสินใจไว้ ข้อความถอดเสียงไม่ได้ถูกใช้ในขั้นตอนการฝึกของระบบที่รับเสียงโดยตรง

การฝึกแบบจัดแนวความหมาย 3 รอบที่มีการบันทึกเวลาใช้เวลา 492.11 วินาที (8 นาที 12 วินาที) บน AMD Radeon RX 9070 XT เวลาดังกล่าวรวมการโหลดโมเดล การเตรียมเวกเตอร์แทนข้อความ การฝึก และการตรวจสอบผลระหว่างฝึก แต่ไม่มีการบันทึกเวลาของการฝึก 10 รอบ จึงยังประมาณเวลาที่ต้องใช้กับการตั้งค่าการทดลองแบบอื่นไม่ได้

3.2 ข้อมูลและวิธีประเมิน

3.2.1 การจำแนกสายโทรศัพท์

ชุดทดสอบภายในประกอบด้วยสายโทรศัพท์ 282 สาย (ช่วงเสียง 576 ช่วง) โดยสายจาก Harper Valley Bank จำนวน 146 สาย ได้รับป้ายกำกับ legitimate ส่วนสายจาก FTC จำนวน 136 สายได้รับป้ายกำกับ spam คำนวณตัวชี้วัดระดับสายด้วยการเฉลี่ยผลจากช่วงเสียงของแต่ละสาย แม้จะแบ่งข้อมูลเป็นชุดฝึกและชุดทดสอบแล้ว แต่ป้ายกำกับแต่ละประเภทผูกกับแหล่งข้อมูลเพียงแหล่งเดียว กล่าวคือ สาย legitimate ทั้งหมดมาจาก Harper ส่วนสาย spam ทั้งหมดมาจาก FTC โมเดลจึงอาจอาศัยแหล่งที่มา ลักษณะการบันทึกเสียง หรือรูปแบบบทสนทนา แทนการเรียนรู้ลักษณะของสาย spam ผลคะแนนนี้อธิบายได้เฉพาะชุดทดสอบ

ดังกล่าว ไม่ใช่ค่าประมาณประสิทธิภาพในการตรวจจับสายไม่พึงประสงค์จากแหล่งข้อมูลจริงที่หลากหลาย

3.2.2 ชุดข้อมูลถ่ายโอน

- **MinDS-14:** ใช้ตัวอย่างทั้ง 563 รายการในชุด **en-US/train** ครอบคลุมเจตนาการใช้บริการธนาคาร 14 ประเภท ชุดเผยแพร่ไม่มีชุดทดสอบอิสระที่กำหนดไว้อย่างเป็นทางการ จึงใช้ข้อมูลทั้งหมดประเมินโดยไม่ปรับพารามิเตอร์ด้วยป้ายกำกับของงานเป้าหมาย ค่าฐานจากการทำนายคลาสที่พบมากที่สุดมี Accuracy 8.5% และ Macro F1 1.1% [5, 6]
- **ชุดข้อมูล Urgency-tone:** ใช้คลิปเสียงภาษาอังกฤษที่สร้างด้วยปัญญาประดิษฐ์จำนวน 40 คลิป แบ่งเป็นคลิปเร่งด่วน (urgent) และไม่เร่งด่วน (not-urgent) อย่างละ 20 คลิป เนื้อหาเหตุการณ์สังเคราะห์อาจบ่งชี้ป้ายกำกับได้เช่นเดียวกับน้ำเสียง ค่าฐานจากการทำนายคลาสที่พบมากที่สุดมี Accuracy 50.0% และ Macro F1 33.3% [7]

ในการประเมินการถ่ายโอนงาน วิธี A และ B ไม่ได้ใช้ป้ายกำกับของงานเป้าหมายระหว่างฝึก ส่วนวิธี C ส่งข้อความที่ Whisper ถอดเสียงให้ Laya สำหรับ MinDS-14 ยังประเมินเพิ่มเติมโดยป้อนข้อความถอดเสียงอ้างอิงให้ Laya ผลจากวิธี C ทั้งสองรูปแบบจึงไม่ใช่ผลจากการป้อนเสียงโดยตรง ส่วนผลจากการฝึกจัดแนวความหมาย 3 รอบไม่เป็นการประเมินอิสระ เพราะกำหนดจำนวนรอบหลังตรวจสอบการทดลองก่อนหน้าบนคลิป 40 รายการชุดเดิม

3.2.3 นิยามตัวชี้วัด

Accuracy คือสัดส่วนตัวอย่างที่จำแนกได้ถูกต้อง ส่วน Macro F1 คำนวณค่า F1 แยกตามคลาสแล้วหาค่าเฉลี่ยโดยให้น้ำหนักแต่ละคลาสเท่ากัน AUROC วัดความสามารถในการจัดอันดับให้ตัวอย่างคลาสบวกสูงกว่าตัวอย่างคลาสลบ เมื่อพิจารณาเกณฑ์ตัดสินหลายค่า สำหรับ MinDS-14 รายงานค่าเฉลี่ยแบบ one-vs-rest (OvR) ค่า AUROC ไม่รับรองว่าการจำแนกที่เกณฑ์ตัดสินเริ่มต้นจะถูกต้อง และไม่ได้แสดงว่าค่าความน่าจะเป็นได้รับการปรับเทียบแล้ว ส่วน $\text{Recall}@k$ คือสัดส่วนของเสียงที่ข้อความถอดเสียงซึ่งเป็นคู่กันปรากฏอยู่ในรายการผู้สมัครอันดับต้น ๆ จำนวน k รายการ

3.3 แนวทางการทำซ้ำและสถานะ

ส่วนนี้จัดรายละเอียดตามหัวข้อใน NeurIPS Paper Checklist Guidelines ที่เกี่ยวข้องกับการทำซ้ำ รายละเอียดการทดลองความไม่แน่นอน ทรัพยากรคำนวณ และสิทธิ์การใช้ทรัพยากร [8] การจัดหัวข้อดังกล่าวมีไว้เพื่อช่วยตรวจสอบความครบถ้วนของรายงาน มิได้หมายความว่างานนี้ส่งหรือผ่านการรับรองจาก NeurIPS

3.3.1 ที่มาของข้อมูลและการแบ่งชุด

รุ่นของแหล่งข้อมูลที่ตรวจสอบและใช้เป็นข้อมูลอ้างอิงในรายงานนี้มีดังนี้:

- คลังข้อมูล FTC Robocall Audio, commit:
5aa6f3bfa8563ce8c1c75ebf8a2271e6ff6b4272
- คลังข้อมูล HarperValleyBank, commit:
0bd721e877c4a85d8c13ff837e68661ea6200a98

- รุนข้อมูล MInDS-14:
40ce77cb32a384e4d50a568e1ec39ac804019d33 ตามที่ระบุในไฟล์กำหนดงาน
- ชุดข้อมูล Urgency-tone รุน 1, ค่า MD5 ของแฟ้มข้อมูล:
427b71b8019b0f7eebccccb162dc594e0

รายงานนี้ไม่ได้เผยแพร่ไฟล์เสียงหรือข้อความถอดเสียง ผู้ใช้ข้อมูลควรตรวจสอบเงื่อนไขการใช้และให้เครดิตตามที่เอกสารของแต่ละแหล่งกำหนด [3, 4, 5, 6, 7]

สคริปต์เตรียมข้อมูล FTC และ Harper สร้างรายการข้อมูล (manifest) สำหรับการฝึก โดยแบ่งสายต้นฉบับตามรหัสสาย (call ID) เป็นชุดฝึก ชุดตรวจสอบ และชุดทดสอบ ในสัดส่วน 80/10/10 ด้วยวิธีแบ่งชั้นตามคลาส และใช้ seed 42 เพื่อควบคุมการสุ่ม จากนั้นจึงแบ่งเสียงแต่ละสายเป็นช่วง โดยเก็บทุกช่วงจากสายเดียวกันไว้ในชุดเดียวกัน ตัวโหนดข้อมูลแปลงเสียงแต่ละช่วงเป็นเสียงช่องสัญญาณเดี่ยว (mono) และปรับอัตราการสุ่มเป็น 16 kHz ด้วยวิธีปรับอัตราการสุ่มแบบ polyphase แต่ละช่วงยาวไม่เกิน 30 วินาที ระหว่างฝึกมีการปรับระดับเสียงและเติมสัญญาณรบกวนเพื่อเพิ่มความหลากหลายของข้อมูล ตามที่กำหนดไว้ในไฟล์ตั้งค่า การแบ่งชุดเช่นนี้ไม่ได้ขจัดความปะปนระหว่างแหล่งข้อมูลกับป้ายกำกับ รายละเอียดการดาวน์โหลดและคัดกรองรายการข้อมูลของชุดประเมินการถ่ายโอนงานอยู่ใน data/raw/external/minds14/README.md และ data/raw/external/urgency-tone/README.md

3.3.2 แบบจำลองและการฝึก

รหัสโมเดลที่ใช้คือ openai/whisper-small.en และ convaiinnovations/laya ไฟล์ configs/poc.yaml กำหนดให้ฝึก 10 รอบ และหยุดก่อนกำหนดหากผลไม่ดีขึ้นติดต่อกัน 3 รอบ ใช้ตัวอย่างครั้งละ 1 รายการในการปรับพารามิเตอร์และตัวทำงานโหนดข้อมูล 2 ตัว อัตราการเรียนรู้ของชั้นแปลงมิติเท่ากับ 10^{-4} และของส่วนหัวตัดสินใจเท่ากับ 10^{-5} กำหนดค่า weight decay ที่ 0.01 จำกัดขนาด gradient ไว้ที่ 1.0 และใช้ seed 42 ระบบใช้การคำนวณแบบความละเอียดผสมเมื่อฮาร์ดแวร์รองรับ จำกัดเสียงฝึกไว้ไม่เกิน 30 วินาทีต่อช่วง และปรับระดับเสียง 3 dB พร้อมเติมสัญญาณรบกวนโดยกำหนดอัตราส่วนสัญญาณต่อสัญญาณรบกวน (SNR) ระหว่าง 25–40 dB การฝึกแบบจัดแนวความหมายกำหนดน้ำหนักฟังก์ชันสูญเสีย 0.05 และค่าอุณหภูมิ (temperature) 0.07 ส่วนการทดลอง 3 รอบระบุจำนวนรอบใหม่ในคำสั่ง โค้ดกำหนดค่า seed ให้ Python, NumPy และ PyTorch แต่ไม่ได้บังคับให้การคำนวณบน GPU ให้ผลซ้ำกันทุกครั้ง

ระบุรหัสโมเดลจาก Hugging Face แต่ไม่ได้บันทึกรหัสรุ่นการของน้ำหนักโมเดล (immutable revision) การดาวน์โหลดด้วยรหัสเดิมในภายหลังจึงอาจได้น้ำหนักคนละรุ่น น้ำหนักโมเดลที่ฝึกแล้วเผยแพร่ที่ <https://huggingface.co/Thanabordee/AudioLaya-poc> ส่วนบันทึกการทดลองยังอยู่ใต้ runs/ และไม่รวมอยู่ในการเผยแพร่

3.3.3 สภาพแวดล้อม คำสั่ง และผลลัพธ์

ไฟล์ README แนะนำ Python 3.10 ขึ้นไป และให้ติดตั้งชุด PyTorch ที่รองรับฮาร์ดแวร์ก่อนติดตั้งแพ็คเกจอื่นจาก requirements.txt ไฟล์ดังกล่าวระบุเพียงเวอร์ชันขั้นต่ำและไม่มีไฟล์ล็อกเวอร์ชันแพ็คเกจ (lockfile) สำเนาโครงการที่ตรวจสอบใช้ Python 3.12.14, PyTorch 2.8.0+rocm7.1.0.lw.git7a520360, Transformers 5.17.0, NumPy 2.5.3 และ scikit-learn 1.9.1 ตัวเลขเหล่านี้อธิบายสภาพแวดล้อมที่ตรวจพบในปัจจุบัน แต่ไม่ได้ยืนยันว่าเป็นสภาพแวดล้อมของการทดลองทุกครั้ง รหัสรุ่นที่เผยแพร่คือ tag **v1.0.0** ในคลังสาธารณะ ซึ่งเก็บการที่ <https://doi.org/10.5281/zenodo.22933034> แต่บันทึกการทดลองเดิมไม่ได้เก็บค่าการตั้งค่าที่ใช้จริง รายการแพ็คเกจ รุ่นโมเดล หรือรุ่นซอร์สโค้ดที่ใช้ในการรันแต่ละครั้งไว้อย่างครบถ้วน คำสั่งต่อไปนี้จึงเป็นแนวทางสำหรับรันการทดลองซ้ำ แต่ยังไม่รับประกันว่าจะได้ผลตรงกันทุกประการหรือเหมือนกันในระดับบิต

ให้รับคำสั่งจากโฟลเดอร์หลักของโครงการหลังจัดเตรียมข้อมูลต้นทางแล้ว คำสั่งช่วงต้นจะดึงคลังข้อมูล FTC และ Harper ตาม commit ที่ตรวจสอบได้ ควรติดตั้ง PyTorch รุ่นที่เหมาะสมกับฮาร์ดแวร์ก่อนติดตั้งแพ็คเกจตามไฟล์ requirements.txt

```
python -m venv .venv
. .venv/bin/activate
# Install a hardware-matched PyTorch build in this environment first.
python -m pip install -r requirements.txt

git clone https://github.com/wspr-ncsu/robocall-audio-dataset.git data/raw/ftc
git -C data/raw/ftc checkout 5aa6f3bfa8563ce8c1c75ebf8a2271e6ff6b4272
git clone \
    https://github.com/cricketclub/gridspace-stanford-harper-valley.git \
    data/raw/harper
git -C data/raw/harper checkout 0bd721e877c4a85d8c13ff837e68661ea6200a98
python -m src.data.prepare_ftc --root data/raw/ftc
python -m src.data.prepare_harper --root data/raw/harper

python -m src.train --experiment projector_only
python -m src.train --experiment projector_head
python -m src.evaluate --checkpoint runs/projector_only/best.pt \
    --out results/projector_only
python -m src.evaluate \
    --checkpoint runs/projector_head/best.pt --out results
python -m src.transcript_baseline

python -m src.train --experiment projector_only \
    --semantic-weight 0.05 --semantic-temperature 0.07 \
    --output-dir runs/projector_semantic
python -m src.semantic_eval \
    --checkpoint runs/projector_semantic/best.pt --split test
python -m src.train --experiment projector_only --epochs 3 \
    --semantic-weight 0.05 --semantic-temperature 0.07 \
    --output-dir runs/projector_semantic_3epochs
python -m src.semantic_eval \
    --checkpoint runs/projector_semantic_3epochs/best.pt --split test

python -m src.transfer_eval --task configs/transfer_minds14.json \
    --out results/transfer/minds14_zero_shot.json
python -m src.transfer_eval --task configs/transfer_urgency.json \
    --skip-gold-transcript --out results/transfer/urgency_zero_shot.json
python -m src.transfer_eval --task configs/transfer_minds14.json \
    --checkpoint-semantic runs/projector_semantic/best.pt \
```

```

--skip-text-baselines \
--out results/transfer/minds14_semantic_zero_shot.json
python -m src.transfer_eval --task configs/transfer_urgency.json \
--checkpoint-semantic runs/projector_semantic/best.pt \
--skip-text-baselines --skip-gold-transcript \
--out results/transfer/urgency_semantic_zero_shot.json
python -m src.transfer_eval --task configs/transfer_minds14.json \
--checkpoint-semantic runs/projector_semantic_3epochs/best.pt \
--skip-text-baselines --out results/transfer/minds14_semantic_3epochs.json
python -m src.transfer_eval --task configs/transfer_urgency.json \
--checkpoint-semantic runs/projector_semantic_3epochs/best.pt \
--skip-text-baselines --skip-gold-transcript \
--out results/transfer/urgency_semantic_3epochs.json
python -m unittest discover -s tests

```

คำสั่งประเมินการถ่ายโอนงานข้างต้นจะประเมิน A และ B เป็นค่าเริ่มต้น ชุดคำสั่งแรกสร้างผลเปรียบเทียบจากข้อความ ส่วนคำสั่งที่ใช้ checkpoint สำหรับการจับแนวความหมายจะไม่สร้างผลเปรียบเทียบดังกล่าวซ้ำ ไฟล์ผลตัวชี้วัด ไฟล์น้ำหนักโมเดล และบันทึกการทดลองบางส่วนอยู่ในโฟลเดอร์ results/ และ runs/ มีเพียงการฝึกแบบจับแนวความหมาย 3 รอบที่บันทึกเวลารวม 492.11 วินาทีและหน่วยความจำอุปกรณ์สูงสุดที่จัดสรร 2,406,236,160 ไบต์ โครงการนี้ไม่มีบันทึกเวลาคำนวณรวม หรือเวลาที่เปรียบเทียบกันได้สำหรับการทดลองอื่น

3.3.4 สรุปตามรายการตรวจสอบ

สถานะต่อไปนีสรุปตามคำถามในรายการตรวจสอบที่อ้างถึง มิใช่คำรับรองอย่างเป็นทางการสำหรับการส่งผลงานเข้าร่วม NeurIPS

- **โค้ด ข้อมูล และคำสั่ง:** บางส่วน รหัสรุ่นที่ติดป้าย (tag v1.0.0) ซึ่งเก็บถาวรที่ <https://doi.org/10.5281/zenodo.22933034> มีสคริปต์ ไฟล์ตั้งค่า คำสั่งที่ใช้จริง และผลลัพธ์ครบถ้วน แต่ไม่ได้เผยแพร่ไฟล์เสียงหรือข้อความถอดเสียง เนื่องจากชุดข้อมูลต้นทางมีเงื่อนไขการใช้ของตัวเอง โดย README อธิบายวิธีดาวน์โหลดและสร้าง manifest ใหม่ น้ำหนักโมเดลที่ฝึกแล้วเผยแพร่แยกที่ <https://huggingface.co/Thanabordee/AudioLaya-poc>
- **รายละเอียดการทดลอง:** บางส่วน ระบุวิธีแบ่งชุดข้อมูลและค่าการฝึกเริ่มต้น พร้อมทั้งไฟล์ตั้งค่าที่เผยแพร่จริง แต่โมเดลฐานอ้างอิงด้วยชื่อ มิได้ระบุรหัสรุ่นที่แน่นอน และไม่มีบันทึกสภาพแวดล้อมที่ยืนยันได้ต่อการรันแต่ละครั้ง
- **นัยสำคัญทางสถิติ:** ยังไม่มี รายงานผลจากการทดลองครั้งเดียว โดยไม่มีการทดลองซ้ำด้วย seed ต่างกัน ช่วงความเชื่อมั่น หรือแถบค่าคลาดเคลื่อน
- **ทรัพยากรคำนวณ:** บางส่วน บันทึกเวลาและหน่วยความจำสูงสุดของการฝึกแบบจับแนวความหมาย 3 รอบไว้ แต่ไม่มีข้อมูลเปรียบเทียบสำหรับการทดลองอื่นหรือยอดการใช้ทรัพยากรคำนวณของโครงการทั้งหมด
- **ทรัพยากรและใบอนุญาต:** บางส่วน ระบุที่มาและเงื่อนไขการใช้ชุดข้อมูลแล้ว และน้ำหนักที่เผยแพร่ใช้สัญญาอนุญาต MIT ของโครงการนี้ ส่วนโมเดลฐานยังอยู่ภายใต้เงื่อนไข Apache-2.0 ของตัวเอง

สถานะความสามารถในการทำซ้ำจึงอยู่ในระดับ **บางส่วน**: รหัสรุ่นที่เผยแพร่รองรับการรันซ้ำได้ แต่ยืนยันยันการทำซ้ำให้ได้ผลตรงกันทุกประการไม่ได้ เนื่องจากผลมาจากการรันครั้งเดียวและยังไม่ระบุรหัสรุ่นของโมเดลฐาน

บทที่ 4

ผลการทดลองและอภิปรายผล

4.1 ผลเชิงปริมาณ

4.1.1 ผลการจำแนกสายไม่พึงประสงค์และสายปกติ

A และ B ใช้เปรียบเทียบการฝึกเฉพาะชั้นแปลงมิติกับการปรับส่วนตัดสินใจของ Laya เพิ่มเติม อย่างไรก็ตาม วิธีทั้งสองไม่ได้ปรับพารามิเตอร์จำนวนเท่ากัน

ตารางที่ 4.1: ผลการจำแนกสายที่มีป้ายกำกับ spam และ legitimate บนชุดทดสอบเดียวกันจำนวน 282 สาย

วิธี	Macro F1	AUROC
A: ฝึกเฉพาะชั้นแปลงมิติ	99.6%	100.0%
B: ปรับชั้นแปลงมิติและส่วนหัวตัดสินใจ	100.0%	100.0%
C: Whisper ASR → Laya	89.2%	94.9%
A + จัดแนวความหมาย, 3 รอบ	99.6%	100.0%
A + จัดแนวความหมาย, 10 รอบ	100.0%	100.0%

คะแนนดังกล่าวแสดงว่าวิธีเสียงตรงทำงานได้ดีบนชุดทดสอบนี้ แต่เมื่อแหล่งข้อมูลกับป้ายกำกับตรงกันทุกกรณีคะแนนก็ยังยืนยันไม่ได้ว่าโมเดลเรียนรู้ลักษณะของสาย spam ที่คงทนต่อการเปลี่ยนแหล่งเสียง เวลาอนุมานเฉลี่ยที่บันทึกไว้ในการประเมินนี้เท่ากับ 55.3 มิลลิวินาทีต่อสายสำหรับ A, 70.9 มิลลิวินาทีต่อสายสำหรับ B และ 762.3 มิลลิวินาทีต่อสายสำหรับ C โดยเส้นทางที่ใช้ ASR ใช้เวลานานกว่าประมาณ 10.8–13.8 เท่า ตัวเลขนี้ขึ้นกับสภาพแวดล้อมการทดลองและความยาวเสียง จึงไม่ใช่ผลเปรียบเทียบความเร็วที่ใช้แทนระบบอื่นได้ทั่วไป

บันทึกโครงการยังระบุผลประเมินเสริมจากสายจำลองการสนทนาบริการปกติ 14 สาย โดย A, B และ C ไม่แจ้งเตือนผิดแม้แต่สายเดียว อย่างไรก็ตาม ชุดนี้มีเฉพาะตัวอย่างปกติและมีขนาดเล็กเกินกว่าจะประมาณอัตราการแจ้งเตือนผิดได้อย่างน่าเชื่อถือ อีกทั้งไม่ได้แนบไฟล์เสียงต้นฉบับและยังไม่ได้ยืนยันสิทธิ์การเผยแพร่ จึงไม่นำผลดังกล่าวมาใช้เป็นหลักฐานหลัก

ตารางที่ 4.2: ผลการถ่ายโอนงาน วิธี C รับข้อความถอดเสียง จึงใช้ข้อมูลเข้าคนละชนิดกับ A และ B

ชุดข้อมูล	วิธี	Accuracy	Macro F1	Macro AUROC (OvR)
MinDS-14	ค่าฐานจากคลาสส่วนใหญ่	8.5%	1.1%	---
	A: ปรับเฉพาะชั้นแปลงมิติ	8.0%	1.4%	49.7%
	B: ปรับชั้นแปลงมิติและส่วนหัวตัดสินใจ	6.2%	2.9%	49.0%
	A + จัดแนวความหมาย, 10 รอบ	8.5%	2.0%	50.8%
	A + จัดแนวความหมาย, 3 รอบ*	6.6%	1.6%	49.8%
	C: Whisper ASR → Laya	93.6%	93.7%	99.3%
	C: ข้อความถอดเสียงอ้างอิง → Laya	90.9%	91.1%	99.0%
ชุดเสียงเร่งด่วน (40 คลิป)	ค่าฐานจากคลาสส่วนใหญ่	50.0%	33.3%	---
	A: ปรับเฉพาะชั้นแปลงมิติ	45.0%	43.7%	51.8%
	B: ปรับชั้นแปลงมิติและส่วนหัวตัดสินใจ	72.5%	70.3%	99.8%
	A + จัดแนวความหมาย, 10 รอบ	52.5%	44.7%	72.8%
	A + จัดแนวความหมาย, 3 รอบ*	80.0%	80.0%	88.8%
	C: Whisper ASR → Laya	97.5%	97.5%	100.0%

4.1.2 ผลการถ่ายโอนงานโดยไม่ปรับแต่งด้วยข้อมูลเป้าหมาย


บน MinDS-14 วิธีที่รับเสียงโดยตรงได้คะแนนใกล้เคียงค่าฐานจากคลาสส่วนใหญ่ และส่วนใหญ่ทำนายเป็นคลาส **cash_deposit** ส่วนคะแนนที่สูงของ C เกิดจากการถอดเสียงด้วย ASR แล้วส่งข้อความให้ Laya จึงสะท้อนประสิทธิภาพของกระบวนการรู้จำเสียงพูดต่อการตัดสินใจจากข้อความ ไม่ได้แสดงว่าชั้นแปลงมิติจากเสียงจำแนกเจตนาทั้ง 14 ประเภทได้ การทดลองที่ใช้ข้อความถอดเสียงอ้างอิงเป็นเพียงการควบคุมเพิ่มเติม เพราะป้อนข้อความอ้างอิงให้โมเดล จึงไม่ได้ใช้ข้อมูลเข้าชนิดเดียวกับวิธีเสียงตรง

บนชุดเสียงเร่งด่วน B ได้ AUROC 99.8% แต่เมื่อใช้เกณฑ์ตัดสินใจเริ่มต้นกลับจำแนกคลิปเร่งด่วนได้เพียง 9 จาก 20 คลิป วิธีจัดแนวความหมายที่ฝึก 10 รอบจำแนกคลิปเร่งด่วนได้ 3 จาก 20 คลิป ขณะที่วิธี 3 รอบจำแนกได้ 16 จาก 20 คลิป ผลจากวิธี 3 รอบเป็นเพียงข้อสังเกตเบื้องต้น เนื่องจากกำหนดจำนวนรอบหลังตรวจสอบหน้าบนคลิป 40 รายการชุดเดียวกัน จึงไม่ใช่ผลทดสอบอิสระ ส่วน C จำแนกคลิปเร่งด่วนได้ 19 จาก 20 คลิปผ่านเส้นทาง ASR แล้วตัดสินใจจากข้อความ ผลทั้งหมดมีความไม่แน่นอนสูงเพราะใช้ตัวอย่างน้อย เป็นเสียงสังเคราะห์ และเนื้อหาอาจบ่งชี้ป้ายกำกับ

ภาพที่ 4.1 วางชุดประเมินทั้งสามไว้บนสเกลเดียวกัน และแสดงให้เห็นว่าช่องว่างระหว่างเส้นทางเสียงโดยตรงกับเส้นทางข้อความนั้นเล็กมากในโดเมน แต่กลายเป็นความแตกต่างทั้งหมดในสถานการณ์ถ่ายโอนงาน โดยวิธีรับเสียงโดยตรงตกอยู่บนเส้นค่าฐานพอดี มิได้อยู่เหนือขึ้นไป

4.1.3 ผลของการจัดแนวความหมายระหว่างเสียงกับข้อความ

ฟังก์ชันสูญเสียแบบเปรียบเทียบช่วยให้ชั้นแปลงมิติค้นพบข้อความถอดเสียงที่เป็นคู่กับเสียงในข้อมูล FTC และ Harper ซึ่งกันไว้จากการฝึกได้ดียิ่งขึ้นอย่างชัดเจน แต่ไม่ได้ทำให้ส่วนหัวตัดสินใจที่ฝึกกับงานจำแนก spam กลายเป็นตัวจำแนกเจตนาทั่วไป แบบจำลองที่จัดแนวความหมาย 10 รอบได้ Accuracy เพียง 8.5% และ Macro F1 2.0% บน MinDS-14 อีกทั้งได้ Accuracy 52.5% บนชุดเสียงเร่งด่วน การจับคู่เวกเตอร์เสียงกับข้อความจึงไม่เท่ากับความสามารถในการตัดสินใจในงานใหม่



รูปที่ 4.1: ความแม่นยำ (accuracy) ของทุกวิธีบนชุดประเมินทั้งสาม ชุด แสดงบนแกนเดียวกันช่วง 0--1 งานจำแนกสายไม่พึงประสงค์ในโดเมนของวิธีรับเสียงโดยตรงได้คะแนนเต็มเปดาน ขณะที่การถ่ายโอนแบบไม่ปรับแต่งไปยัง MinDS-14 ตกลงมาอยู่ที่ระดับค่าฐานจากคลาสส่วนใหญ่ โดยเส้นประคือค่าฐานของแต่ละชุด ลายทแยงใช้กำกับเส้นทาง C ซึ่งรับข้อความถอดเสียง จึงไม่ใช่เส้นทางข้อมูลเข้าชนิดเดียวกับ A และ B แห่งของวิธี 3 รอบบนชุดเสียงเร่งด่วนเป็นผลเชิงสำรวจ เพราะเลือกจำนวนรอบหลังเห็นผลการประเมินเดิมบนคลิปปชุดเดียวกัน

ตารางที่ 4.3: ผลการค้นข้อความถอดเสียงจากเสียงที่กั้นไว้จากการฝึก จำนวน 445 รายการ จากตัวเลือกข้อความ 413 รายการ ค่า Recall@1 เมื่อสุ่มเลือกอยู่ที่ประมาณ 0.24%

แบบจำลองที่ประเมิน	ค่าฟังก์ชันสูญเสียในการค้นคืน	Recall@1	Recall@5
A ไม่จัดแนวความหมาย	6.079	0.2%	1.1%
A จัดแนวความหมาย 3 รอบ	4.041	16.4%	52.1%
A จัดแนวความหมาย 10 รอบ	3.590	33.3%	74.8%

4.2 การตีความผล

ผลการทดลองสอดคล้องกับสมมติฐานของ **การปรับโมเดลให้เชี่ยวชาญเฉพาะงานแบบแยกส่วน**: ตรึงตัวเข้ารหัสที่ผ่านการฝึกล่วงหน้า ฝึกชั้นแปลงมิติเพื่อเชื่อมรูปแบบข้อมูลใหม่ และปรับส่วนหัวตัดสินใจเพิ่มเติมเมื่อจำเป็น วิธี A ปรับพารามิเตอร์ 1.84 ล้านตัว ส่วนวิธี B ปรับ 28.09 ล้านตัว การฝึก 3 รอบที่จับเวลาไว้ใช้เวลาประมาณ 8 นาทีบน GPU ระดับผู้ใช้ทั่วไปหนึ่งตัว เมื่อพิจารณาเป็นชุดของโมเดลเฉพาะงาน แนวทางนี้สอดคล้องกับสถาปัตยกรรมแบบ System-1 ซึ่งตัวเข้ารหัสและตัวปรับเฉพาะรูปแบบข้อมูลส่งต่อผลให้ระบบตัดสินใจเฉพาะงาน อย่างไรก็ตาม แนวคิดดังกล่าวยังเป็นสมมติฐานสำหรับการพัฒนาสถาปัตยกรรมในอนาคต เพราะรายงานนี้ทดสอบเฉพาะเส้นทางเสียง

จำนวนพารามิเตอร์ที่ปรับไม่ได้สะท้อนขนาดของระบบเมื่อนำไปใช้งานจริง: ตามเอกสารกำกับโมเดล Laya มีพารามิเตอร์ 421 ล้านตัว และระบบยังต้องใช้ตัวเข้ารหัส Whisper ด้วย ขณะเดียวกัน ผลการถ่ายโอนจากเสียงโดยตรงยังอยู่ในระดับต่ำ และชุดทดสอบ spam หลักยังปะปนแหล่งข้อมูลกับป้ายกำกับ หลักฐานที่มีจึงรองรับการศึกษาต่อยอดแนวทางวิศวกรรมนี้ แต่ยังไม่รองรับข้ออ้างว่าโมเดลเข้าใจเสียงได้ทั่วไป

ระบบตัดสินใจแบบกำหนดชนิดผลลัพธ์ (typed decision) อาจพัฒนาให้ส่งผลลัพธ์ในรูปแบบมีโครงสร้าง เช่น:

```
{"spam": true, "risk": "high", "action": "block"}
```

ตัวอย่าง JSON นี้เป็นเพียงแนวทางสำหรับการพัฒนาต่อ ไม่ใช่รูปแบบผลลัพธ์ (schema) ที่ผ่านการทดลองครบถ้วน การทดลองปัจจุบันทดสอบผลการจำแนกหลัก ๆ เพียงสองตัวเลือก คือ spam และ legitimate นอกจากนี้ ระบบยังแจ้งเตือนว่าคะแนนไม่ได้ผ่านการปรับเทียบ จึงไม่ควรตีความคะแนนที่รายงานว่าเป็นค่าความเชื่อมั่นที่ปรับเทียบแล้ว

บทที่ 5

ข้อจำกัด การใช้อย่างรับผิดชอบ และบทสรุป

5.1 ข้อจำกัดและการใช้อย่างรับผิดชอบ

การตีความผลการทดลองต้องคำนึงถึงข้อจำกัดต่อไปนี้:

1. **แหล่งข้อมูลปะปนกับป้ายกำกับ:** ในชุดทดสอบ spam ภายใน แหล่งข้อมูลตรงกับป้ายกำกับอย่างสมบูรณ์ จึงควรประเมินเพิ่มเติมกับแหล่งเสียงที่ไม่เคยพบ และกำหนดป้ายกำกับโดยไม่ผูกกับแหล่งข้อมูล
2. **ชุดประเมินการถ่ายโอนมีขนาดเล็กหรือไม่เป็นอิสระ:** MinDS-14 ไม่มีชุดทดสอบแยกที่กำหนดไว้อย่างเป็นทางการ ชุดเสียงเร่งด่วนมีเสียงสังเคราะห์เพียง 40 คลิป และกำหนดจำนวนรอบของผล 3 รอบหลังตรวจผลชุดเดิมแล้ว
3. **วิธีรับข้อมูลต่างกัน:** A และ B รับเสียงโดยตรง ส่วน C ถอดเสียงก่อนส่งข้อความให้ Laya ผลของทั้งสองเส้นทางจึงตอบคำถามคนละข้อ
4. **โมเดลฐานมีความรู้เดิม:** Laya เป็นโมเดลตัดสินใจจากข้อความที่ผ่านการฝึกล่วงหน้า งานนี้ไม่ได้แยกผลของการเชื่อมโยงออกจากความสามารถด้านข้อความที่มีอยู่เดิม
5. **ขนาดและต้นทุนการใช้งาน:** จำนวนพารามิเตอร์ที่ปรับและเวลาจากการทดลองครั้งเดียวไม่ได้บอกการใช้หน่วยความจำพลังงาน หรือต้นทุนอนุมานทั้งหมด ไม่มีการบันทึกเวลาฝึก 10 รอบ และเวลาอนุมานต่อสายขึ้นกับฮาร์ดแวร์กับความยาวเสียง
6. **ความไม่แน่นอนและเงื่อนไขเปรียบเทียบ:** รายงานผลจากการทดลองครั้งเดียว ไม่มีการทดลองซ้ำด้วย seed ต่างกัน หรือช่วงความเชื่อมั่น วิธี B ปรับพารามิเตอร์มากกว่า A ประมาณ 15 เท่า จึงไม่ใช่การทดลองแยกผลที่ควบคุมจำนวนพารามิเตอร์ให้เท่ากัน และความแตกต่างของคะแนนเพียงเล็กน้อยยังไม่มีหลักฐานว่ามีนัยสำคัญทางสถิติ
7. **บันทึกการทดลองยังไม่พอสำหรับทำซ้ำให้ตรงกัน:** ไม่ได้ระบุ revision ของน้ำหนัโมเดลอย่างถาวร ไม่มีไฟล์ล็อกเวอร์ชันแพ็กเกจหรือรหัส Git revision ของซอร์สโค้ด และบันทึกการทดลองในอดีตไม่ได้เก็บสภาพแวดล้อมกับค่าตั้งค่าที่ใช้จริงไว้อย่างครบถ้วน จึงรับประกันผลที่ตรงกันทุกประการไม่ได้

8. **ยังไม่มีผลทดสอบกับรูปแบบข้อมูลอื่น:** ไม่ได้ประเมินข้อมูลภาพ วิดีโอ หรือข้อมูลจากเซนเซอร์

9. **ข้อจำกัดในการใช้งานจริง:** ระบบนี้เป็นต้นแบบเพื่อการวิจัย ยังไม่ได้รับการยืนยันสำหรับใช้บล็อกสายโทรศัพท์ ไม่ควรใช้คะแนนที่ยังไม่ได้ปรับเทียบประกอบการตัดสินใจที่มีผลกระทบสูง หากไม่มีการตรวจสอบอิสระ การเลือกเกณฑ์ตัดสินใจ และการวิเคราะห์ข้อผิดพลาด

การศึกษาควรเพิ่มข้อมูลเสียงและความถี่เสียงที่หลากหลายทั้งผู้พูด สำเนียง เนื้อหา และสภาพการบันทึก พร้อมกันผู้พูดและคลังข้อมูลบางส่วนออกจากชุดฝึก ควรประเมินส่วนหัวตัดสินใจกับงานที่ใช้ป้ายกำกับอิสระ และไม่ใช่ชุดทดสอบสุดท้ายเลือกน้ำหนักโมเดลหรือจำนวนรอบฝึก สำหรับงานจำแนกความเร่งด่วน ควรเพิ่มเสียงจากผู้พูดจริงและกำหนดต้นทุนของการแจ้งเตือนผิดกับการพลาดเหตุเร่งด่วนก่อนการใช้งานจริง ส่วนรูปแบบข้อมูลอื่นต้องประเมินในการทดลองใหม่ ไม่ควรอนุมานผลจากการทดลองเสียง

5.2 สรุป

Audio-Laya เป็นการทดลองเบื้องต้นของแนวทางที่นำไปปรับใช้กับงานอื่นได้ โดยตรงตัวเข้ารหัสของรูปแบบข้อมูลผ่านการฝึกล่วงหน้า ฝึกชั้นแปลงมิติขนาดเล็ก และปรับส่วนหัวตัดสินใจเฉพาะงานเมื่อจำเป็น ผลบนชุดทดสอบภายในแสดงว่าแนวทางนี้ทำคะแนนได้สูงกับงานจำแนกเสียงที่กำหนดไว้ แต่ความปะปนระหว่างแหล่งข้อมูลกับป้ายกำกับยังทำให้สรุปประสิทธิภาพการตรวจจับ spam ทั่วไปไม่ได้ ผลการถ่ายโอนงานและการจัดแนวความหมายยังชี้ว่า การดึงข้อความถอดเสียงที่สัมพันธ์กับเสียงได้ดีขึ้นไม่ได้ทำให้ระบบตัดสินใจในงานใหม่ได้เอง หลักฐานในปัจจุบันจึงสนับสนุนเพียงว่า การปรับโมเดลให้เชี่ยวชาญเฉพาะงานมีแนวโน้มที่ควรศึกษาเพิ่มเติม ส่วนความสามารถในการใช้ได้ทั่วไปยังไม่ได้รับการพิสูจน์

เอกสารอ้างอิง

- [1] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, "Robust Speech Recognition via Large-Scale Weak Supervision," in *Proceedings of the 40th International Conference on Machine Learning*, vol. 202, pp. 28492–28518, 2023. <https://proceedings.mlr.press/v202/radford23a.html>
- [2] Convai Innovations, "Laya: typed-decision model," model card, Hugging Face. <https://huggingface.co/convaiinnovations/laya>. เข้าถึง กันยายน 2026.
- [3] S. Prasad and B. Reaves, "Robocall Audio from the FTC's Project Point of No Entry," North Carolina State University, Technical Report TR-2023-1, 2023. <https://www.csc2.ncsu.edu/techreports/tech/2023/TR-2023-1.pdf>
- [4] M. Wu, J. Nafziger, A. Scodary, and A. Maas, "HarperValleyBank: A Domain-Specific Spoken Dialog Corpus," arXiv:2010.13929, 2020. <https://arxiv.org/abs/2010.13929>
- [5] D. Gerz et al., "Multilingual and Cross-Lingual Intent Detection from Spoken Data," in *Proceedings of EMNLP*, 2021. <https://doi.org/10.18653/v1/2021.emnlp-main.591>
- [6] PolyAI, "MInDS-14 dataset," Hugging Face Datasets, CC BY 4.0. <https://huggingface.co/datasets/PolyAI/minds14>
- [7] S. Pinna, F. M. Mallocci, M. Marras, D. Reforgiato Recupero, D. Riboni, and G. Scarpi, "Multilingual speech dataset with urgency tone annotation," Zenodo, version 1, 2025. doi:10.5281/zenodo.17502378.
- [8] NeurIPS, "Paper Checklist Guidelines," 2026. <https://neurips.cc/public/guides/PaperChecklist>. Accessed September 2026.