

Audio-Laya: การเชื่อมคุณลักษณะเสียงเข้ากับโมเดลตัดสินใจที่ผ่านการ ฝึกล่วงหน้าด้วยชั้นแปลงมิติ

รายงานทางเทคนิคว่าด้วยการคัดกรองสายโทรศัพท์ การฝึกจับคู่เสียงกับข้อความ และการประเมินกับงาน
ใหม่

ธนบดี นามมงคล

ORCID: [0009-0004-9410-9839](https://orcid.org/0009-0004-9410-9839)

ฉบับ 1.0.2 • กันยายน 2026

บทคัดย่อ

งานนี้ศึกษาการนำคุณลักษณะเสียงจาก Whisper มาใช้กับ Laya ซึ่งเดิมเป็นโมเดลตัดสินใจจากข้อความ โดยตรงตัวเข้ารหัสเสียงไว้ แล้วฝึกชั้นแปลงมิติ (projector) เป็นตัวเชื่อม บนชุดทดสอบ 282 สาย วิธี A ซึ่งฝึกเฉพาะชั้นแปลงมิติได้ Macro F1 99.6% วิธี B ซึ่งปรับส่วนตัดสินใจร่วมด้วยได้ 100.0% ส่วนวิธี C ซึ่งถอดเสียงด้วย Whisper ก่อนส่งข้อความให้ Laya ได้ 89.2% แต่ชุดทดสอบนี้ใช้สายจาก FTC เป็นตัวอย่าง spam ทั้งหมด และสายจาก Harper เป็นตัวอย่าง legitimate ทั้งหมด แหล่งข้อมูลจึงตรงกับป้ายกำกับทุกกรณี คะแนนดังกล่าวยังบอกไม่ได้ว่าโมเดลจะจำแนกสายจากแหล่งข้อมูลอื่นได้ดีเพียงใด

เมื่อทดสอบการจำแนกเจตนาบน MinDS-14 วิธีที่รับเสียงโดยตรงมีความแม่นยำใกล้เคียงหรือต่ำกว่าการทลายคลาสที่พบบ่อยที่สุด ส่วนผลการจำแนกความเร่งด่วนจากเสียงสังเคราะห์ 40 คลิปยังไม่แน่นอน การฝึกจับคู่เสียงกับข้อความถอดเสียง (semantic alignment) ช่วยให้ค้นคืนข้อความคู่กันได้ดีขึ้น แต่ไม่ได้ช่วยให้จำแนกงานใหม่ได้ดีขึ้นอย่างสม่ำเสมอ การฝึกแบบนี้ 3 รอบที่มีบันทึกเวลาใช้เวลา 492.11 วินาทีบน AMD Radeon RX 9070 XT ผลที่ได้แสดงความเป็นไปได้ของการปรับโมเดลให้ใช้กับงานเฉพาะ แต่ยังไม่ใช้หลักฐานว่าโมเดลเข้าใจเสียงได้ทุกงาน แม้จำนวนพารามิเตอร์ที่ฝึกจะน้อยเมื่อเทียบกับโมเดลฐาน ระบบยังต้องใช้ตัวเข้ารหัส Whisper และโมเดล Laya ขณะอนุมาน

คำสำคัญ: การจำแนกเสียงพูด; การปรับโมเดลให้รับข้อมูลเสียง; ชั้นแปลงมิติ; ตัวเข้ารหัสที่ตรงพารามิเตอร์; โมเดลตัดสินใจแบบกำหนดชนิดผลลัพธ์; การคัดกรองสายโทรศัพท์; การฝึกจับคู่เสียงกับข้อความ

สารบัญ

1	บทนำ	1
1.1	สรุปสำหรับผู้อ่านทั่วไป	1
1.2	คำถามวิจัยและขอบเขต	1
2	พื้นฐานและสถาปัตยกรรมระบบ	2
2.1	องค์ประกอบของแบบจำลอง	2
3	ระเบียบวิธีวิจัยและการประเมินผล	3
3.1	การฝึกและการจับคู่เสียงกับข้อความ	3
3.2	ข้อมูลและวิธีประเมิน	3
3.2.1	การจำแนกสายโทรศัพท์	3
3.2.2	ชุดข้อมูลสำหรับทดสอบกับงานใหม่	4
3.2.3	นิยามตัวชี้วัด	4
3.3	ข้อมูลสำหรับการทำซ้ำ	4
3.3.1	ที่มาของข้อมูลและการแบ่งชุด	4
3.3.2	แบบจำลองและค่าการฝึก	5
3.3.3	สภาพแวดล้อม คำสั่ง และผลลัพธ์	5
3.3.4	สรุปตามรายการตรวจสอบ	7
4	ผลการทดลองและอภิปรายผล	8
4.1	ผลเชิงปริมาณ	8
4.1.1	ผลการจำแนกสายไม่พึงประสงค์และสายปกติ	8
4.1.2	ผลการจำแนกงานใหม่โดยไม่ฝึกเพิ่มเติม	8
4.1.3	ผลของการฝึกจับคู่เสียงกับข้อความ	9
4.2	การตีความผล	10
5	ข้อจำกัด การใช้อย่างรับผิดชอบ และบทสรุป	11
5.1	ข้อจำกัดและการใช้อย่างรับผิดชอบ	11

5.2	สรุป	12
	เอกสารอ้างอิง	13

บทที่ 1

บทนำ

1.1 สรุปสำหรับผู้อ่านทั่วไป

Audio-Laya ใช้ Whisper แปลงเสียงเป็นคุณลักษณะ แล้วฝึกชั้นแปลงมิติให้ Laya นำข้อมูลนั้นไปจำแนกสายไม่พึงประสงค์ (spam) กับสายปกติ (legitimate) โดยไม่ปรับพารามิเตอร์ของ Whisper

วิธีที่รับเสียงโดยตรงได้คะแนนสูงบนสายทดสอบ 282 สาย แต่สาย spam ทั้งหมดมาจาก FTC ส่วนสาย legitimate ทั้งหมดมาจาก Harper โมเดลจึงอาจจำแนกแหล่งที่มาของเสียง แทนที่จะจำแนกประเภทของสาย เมื่อทดลองจำแนกเจตนาจากเสียงในชุดข้อมูลธนาคารอีกชุดหนึ่ง ความแม่นยำก็ไม่สูงกว่าการทายคลาสที่พบบ่อยที่สุด ผลการทดลองจึงยังไม่ยืนยันว่าระบบจะคัดกรองสายจากแหล่งข้อมูลอื่นได้

1.2 คำถามวิจัยและขอบเขต

Whisper มีตัวเข้ารหัสเสียงที่ผ่านการฝึกมาก่อน ส่วน Laya เป็นโมเดลตัดสินใจจากข้อความ [1, 2] งานนี้ถามว่า หากตรึง Whisper ไว้ จะฝึกชั้นแปลงมิติให้ Laya จำแนกสายโทรศัพท์จากเสียงได้หรือไม่ วิธี A ฝึกเฉพาะชั้นแปลงมิติ ส่วนวิธี B ปรับส่วนตัดสินใจของ Laya รวมด้วย สำหรับวิธี C นั้น Whisper ถอดเสียงเป็นข้อความก่อนให้ Laya จำแนก จึงใช้เปรียบเทียบผลของกระบวนการอีกแบบหนึ่ง ไม่ใช่การทดลองที่ให้ทั้งสามวิธีรับข้อมูลชนิดเดียวกัน

การทดลองใช้สายทดสอบจาก FTC และ Harper ที่ไม่อยู่ในชุดฝึก แล้วนำโมเดลไปจำแนกเจตนาบน MInDS-14 และจำแนกความเร่งด่วนบนชุดเสียงสังเคราะห์ โดยไม่ฝึกเพิ่มด้วยป้ายกำกับของสองงานนี้ นอกจากนี้ยังทดสอบว่าการฝึกให้เสียงจับคู่กับข้อความถอดเสียงช่วยให้โมเดลตัดสินใจในงานใหม่ได้หรือไม่ การทดสอบด้วย FTC/Harper ยังแยกผลของแหล่งข้อมูลออกจากป้ายกำกับไม่ได้ ส่วนชุดทดสอบการถ่ายโอนงานก็มีข้อจำกัดด้านขนาดและลักษณะข้อมูล

วิธีที่รับเสียงโดยตรงส่งเสียงผ่านตัวเข้ารหัส Whisper-small.en ที่ตรึงพารามิเตอร์ ชั้นแปลงมิติจาก 768 เป็น 1024 มิติ และส่วนตัดสินใจของ Laya ซึ่งตรึงหรือปรับพารามิเตอร์บางส่วนตามวิธีที่ใช้ วิธีนี้ไม่ต้องถอดเสียงขณะอนุมาน ข้อความถอดเสียงใช้เฉพาะตอนฝึกการจับคู่เสียงกับข้อความเท่านั้น งานนี้ไม่ได้ทดสอบข้อมูลภาพ วิดีโอ หรือเซนเซอร์

บทที่ 2

พื้นฐานและสถาปัตยกรรมระบบ

2.1 องค์ประกอบของแบบจำลอง

การทดลองใช้แบบจำลองสองส่วนหลัก ได้แก่:

- ตัวเข้ารหัสเสียง Whisper-small.en: [openai/whisper-small.en](https://openai.com/whisper-small.en)
- โมเดลตัดสินใจ Laya: [convaiinnovations/laya](https://convaiinnovations.com/laya) [1, 2]

ขั้นแปลงมิติแปลงคุณลักษณะเสียงจาก 768 เป็น 1024 มิติ เพื่อให้ Laya รับข้อมูลได้ Laya พัฒนาจาก ModernBERT-large ที่ฝึกกับข้อความมาก่อน จึงไม่ใช่โมเดลเสียงที่สร้างขึ้นสำหรับการทดลองนี้

ตารางที่ 2.1: ส่วนที่ฝึกในแต่ละวิธี จำนวนพารามิเตอร์เป็นเฉพาะส่วนที่ปรับเปลี่ยน ไม่ใช่ขนาดรวมของโมเดลขณะอนุมาน

วิธี	ส่วนที่ปรับระหว่างฝึก	จำนวนพารามิเตอร์ที่ปรับ
A: ฝึกเฉพาะขั้นแปลงมิติ	ฝึกขั้นแปลงมิติ; ตรึงส่วนตัดสินใจของ Laya	1,838,592
B: ปรับขั้นแปลงมิติและส่วนตัดสินใจ	ขั้นแปลงมิติ, เวกเตอร์แทนประเภทผลลัพธ์ (type embedding), โครงข่าย Transformer สำหรับตัดสินใจ และตัวให้คะแนนตัวเลือกของ Laya	28,086,785
C: ASR → Laya	ไม่ฝึกเพิ่มสำหรับงานนี้; Whisper ถอดเสียงเป็นข้อความก่อนส่งให้ Laya รุ่นมาตรฐาน	0
A + จับคู่เสียงกับข้อความ	ฝึกเฉพาะขั้นแปลงมิติ; เพิ่มการฝึกจับคู่เสียงกับข้อความถอดเสียง	1,838,592

เอกสารกำกับโมเดล (model card) ระบุว่า Laya มีพารามิเตอร์ 421 ล้านตัว ในรายงานนี้ คำว่า “ขนาดเล็ก” จึงหมายถึงเฉพาะจำนวนพารามิเตอร์ที่ฝึกเพิ่มและเวลาการฝึกที่วัดได้ ไม่ได้หมายถึงขนาดโมเดล หน่วยความจำ หรือภาระประมวลผลของระบบขณะใช้งาน เพราะยังต้องโหลดทั้ง Whisper และ Laya เอกสารฉบับเดียวกันระบุว่า Laya รองรับงานจำแนกข้อความและงานที่เกี่ยวกับ spam อยู่แล้ว การทดลองนี้จึงทดสอบการนำเสียงมาใช้กับความสามารถเดิมของ Laya ไม่ใช่การสอนให้โมเดลรู้จัก spam ตั้งแต่ต้น [2]

บทที่ 3

ระเบียบวิธีวิจัยและการประเมินผล

3.1 การฝึกและการจับคู่เสียงกับข้อความ

งานหลักคือการจำแนกเสียงโทรศัพท์เป็น spam หรือ legitimate ด้วยข้อมูลที่มีป้ายกำกับ วิธี A และ B ใช้เสียงร่วมกับคำสั่งงานและคำอธิบายตัวเลือกที่กำหนดไว้ตายตัว แต่ไม่ใช้ข้อความถอดเสียง ส่วนวิธี C ให้ Whisper รู้จำเสียงพูดอัตโนมัติ (ASR) แล้วส่งข้อความถอดเสียงให้ Laya รุ่นที่ไม่ได้ปรับกับงานนี้ วิธีรับเสียงกับวิธีรับข้อความจึงใช้ข้อมูลต่างชนิดกัน คะแนนของทั้งสองเส้นทางไม่ใช่การเปรียบเทียบภายใต้เงื่อนไขเดียวกัน

การทดลองจับคู่เสียงกับข้อความถอดเสียงใช้ข้อมูลจากชุดฝึก FTC และ Harper รวม 22.91 ชั่วโมง ครอบคลุม 1,926 สาย แบ่งเป็นช่วงเสียงที่มีข้อความคู่กัน 3,520 ช่วง และมีข้อความถอดเสียงที่ไม่ซ้ำ 3,028 รายการ ขึ้นแปลงมิติฝึกด้วยฟังก์ชันสูญเสียต่อไปนี้:

$$\mathcal{L} = \mathcal{L}_{\text{spam}} + 0.05 \mathcal{L}_{\text{InfoNCE}}, \quad \tau = 0.07, \quad (3.1)$$

พจน์ InfoNCE เป็นฟังก์ชันสูญเสียแบบเปรียบเทียบ (contrastive loss) ที่ฝึกให้เวกเตอร์ของเสียงจับคู่กับเวกเตอร์ของข้อความถอดเสียง ในการทดลองนี้ตรึงตัวเข้ารหัส Whisper ตัวเข้ารหัสข้อความของ Laya และส่วนตัดสินใจไว้ ข้อความถอดเสียงใช้ระหว่างฝึกเท่านั้น ไม่ได้ป้อนให้วิธีรับเสียงโดยตรงขณะอนุมาน

การฝึกแบบจับคู่เสียงกับข้อความ 3 รอบใช้เวลา 492.11 วินาที (8 นาที 12 วินาที) บน AMD Radeon RX 9070 XT โดยนับตั้งแต่โหลดโมเดล เตรียมเวกเตอร์ข้อความ ฝึก และประเมินระหว่างฝึก ไม่มีบันทึกเวลาที่เปรียบเทียบกันได้สำหรับการฝึก 10 รอบ จึงนำตัวเลขนี้ไปอ้างเป็นเวลาฝึกของการตั้งค่าอื่นไม่ได้

3.2 ข้อมูลและวิธีประเมิน

3.2.1 การจำแนกสายโทรศัพท์

ชุดทดสอบภายในมีสายโทรศัพท์ 282 สาย แบ่งเป็นเสียงย่อย 576 ช่วง ในจำนวนนี้ สายจาก Harper Valley Bank 146 สายมีป้ายกำกับ legitimate และสายจาก FTC 136 สายมีป้ายกำกับ spam การคำนวณคะแนนระดับสายใช้ค่าเฉลี่ยจากทุกช่วงเสียงของสายนั้น แม้จะแยกสายทดสอบออกจากชุดฝึก แต่สาย legitimate ทั้งหมดมาจาก Harper ส่วนสาย spam ทั้งหมดมาจาก FTC โมเดลจึงอาจใช้ลักษณะของแหล่งข้อมูล การบันทึกเสียง หรือบทสนทนา แทนลักษณะของสาย spam คะแนนที่รายงานสะท้อนผลบนชุดนี้เท่านั้น ยังใช้ประมาณประสิทธิภาพกับสายจากแหล่งอื่นไม่ได้

3.2.2 ชุดข้อมูลสำหรับทดสอบกับงานใหม่

- **MInDS-14:** ใช้ตัวอย่างทั้ง 563 รายการในชุด **en-US/train** ครอบคลุมเจตนาการใช้บริการธนาคาร 14 ประเภท รุ่นที่นำมาใช้ไม่มีชุดทดสอบที่ผู้เผยแพร่แยกไว้ จึงใช้ตัวอย่างทั้งหมดประเมินโดยไม่ฝึกเพิ่มด้วยป้ายกำกับของงานนี้ หากทนายคลาสที่พบบ่อยที่สุดทุกครั้ง จะได้ Accuracy 8.5% และ Macro F1 1.1% [5, 6]
- **ชุดข้อมูล Urgency-tone:** ใช้คลิปเสียงภาษาอังกฤษที่สร้างด้วยปัญญาประดิษฐ์จำนวน 40 คลิป แบ่งเป็นคลิปเร่งด่วน (urgent) และไม่เร่งด่วน (not-urgent) อย่างละ 20 คลิป เนื้อหาที่พูดอาจบอกได้ว่าเป็นกรณีเร่งด่วนหรือไม่ โดยไม่ต้องฟังน้ำเสียง หากทนายคลาสที่พบบ่อยที่สุดทุกครั้ง จะได้ Accuracy 50.0% และ Macro F1 33.3% [7]

วิธี A และ B ไม่ได้ฝึกด้วยป้ายกำกับของงานใหม่ ส่วนวิธี C ถอดเสียงด้วย Whisper ก่อนให้ Laya จำแนก สำหรับ MInDS-14 ยังมีผลจากการป้อนข้อความถอดเสียงอ้างอิงให้ Laya เพื่อใช้เปรียบเทียบอีกชุดหนึ่ง ผลทั้งสองแบบที่ใช้ข้อความไม่ใช่ผลจากการจำแนกเสียงโดยตรง นอกจากนี้ ผลของวิธีจับคู่เสียงกับข้อความที่ฝึก 3 รอบยังไม่ใช่การทดสอบอิสระ เพราะเลือกจำนวนรอบหลังเห็นผลบนคลิปเร่งด่วน 40 รายการชุดเดิม

3.2.3 นิยามตัวชี้วัด

Accuracy คือสัดส่วนที่จำแนกถูกต้อง ส่วน Macro F1 คือค่าเฉลี่ย F1 ของทุกคลาสโดยให้น้ำหนักเท่ากัน AUROC วัดว่าคะแนนของโมเดลจัดอันดับตัวอย่างคลาสบวกไว้เหนือคลาสลบได้ดีเพียงใดเมื่อเปลี่ยนเกณฑ์ตัดสิน สำหรับ MInDS-14 ใช้ค่า AUROC เฉลี่ยแบบ one-vs-rest (OvR) ค่า AUROC สูงไม่ได้หมายความว่าโมเดลจำแนกถูกต้องเมื่อใช้เกณฑ์เริ่มต้น หรือว่าคะแนนผ่านการเปรียบเทียบแล้ว ส่วน Recall@ k คือสัดส่วนของเสียงที่พบข้อความถอดเสียงคู่กันในตัวเลือกอันดับต้น k รายการ

3.3 ข้อมูลสำหรับการทำซ้ำ

ส่วนนี้รายงานข้อมูลตามหัวข้อที่เกี่ยวข้องใน NeurIPS Paper Checklist Guidelines ได้แก่ วิธีทดลอง ความไม่แน่นอน ทรัพยากรคำนวณ และสิทธิ์การใช้ข้อมูล [8] การใช้หัวข้อเหล่านี้ไม่ได้หมายความว่างานนี้ส่งหรือผ่านการรับรองจาก NeurIPS

3.3.1 ที่มาของข้อมูลและการแบ่งชุด

แหล่งข้อมูลรุ่นที่ตรวจสอบสำหรับรายงานนี้มีดังนี้:

- คลังข้อมูล FTC Robocall Audio, commit:
5aa6f3bfa8563ce8c1c75ebf8a2271e6ff6b4272
- คลังข้อมูล HarperValleyBank, commit:
0bd721e877c4a85d8c13ff837e68661ea6200a98
- รุ่นข้อมูล MInDS-14:
40ce77cb32a384e4d50a568e1ec39ac804019d33 ตามที่ระบุในไฟล์กำหนดงาน
- ชุดข้อมูล Urgency-tone รุ่น 1, ค่า MD5 ของแฟ้มข้อมูล:
427b71b8019b0f7eebcccb162dc594e0

รายงานนี้ไม่แจกจ่ายไฟล์เสียงหรือข้อความถอดเสียง ผู้ที่นำข้อมูลไปใช้ต้องตรวจสอบเงื่อนไขและอ้างอิงแหล่งข้อมูลตามที่ผู้เผยแพร่กำหนด [3, 4, 5, 6, 7]

สคริปต์เตรียมข้อมูล FTC และ Harper บันทึกการรายการข้อมูล (manifest) สำหรับฝึกและประเมิน โดยสุ่มแยกสายโทรศัพท์ตามรหัสสาย (call ID) เป็นชุดฝึก ชุดตรวจสอบ และชุดทดสอบในสัดส่วนประมาณ 80/10/10 แยกตามคลาส และใช้ seed 42 จากนั้นจึงแบ่งเสียงเป็นช่วง ทำให้ช่วงเสียงจากสายเดียวกันอยู่ในชุดเดียวกันทุกช่วง

ตัวโหลดข้อมูลแปลงเสียงเป็นช่องสัญญาณเดียว (mono) และใช้อัลกอริทึม polyphase ปรับอัตราสุ่มเป็น 16 kHz แต่ละช่วงยาวไม่เกิน 30 วินาที ระหว่างฝึกมีการปรับระดับเสียงและเติมสัญญาณรบกวนตามไฟล์ตั้งค่า การแยกสายเช่นนี้ไม่ได้แก้ปัญหาที่แหล่งข้อมูลตรงกับป้ายกำกับ รายละเอียดการเตรียมชุดทดสอบงานใหม่อยู่ใน data/raw/external/minds14/README.md และ data/raw/external/urgency-tone/README.md

3.3.2 แบบจำลองและค่าการฝึก

การทดลองใช้โมเดล openai/whisper-small.en และ convaiinnovations/laya ค่าตั้งต้นใน configs/poc.yaml คือฝึกไม่เกิน 10 รอบ หยุดหากคะแนนไม่ดีขึ้น 3 รอบติดต่อกัน ใช้ครั้งละ 1 ช่วงเสียง และใช้ตัวโหลดข้อมูล 2 กระบวนการ อัตราการเรียนรู้ของชั้นแปลงมิติคือ 10^{-4} ส่วนขององค์ประกอบตัดสินใจคือ 10^{-5} ใช้ weight decay 0.01 จำกัดบรรทัดฐานเกรเดียนต์ที่ 1.0 และกำหนด seed 42

ระบบคำนวณแบบความละเอียดผสมเมื่อฮาร์ดแวร์รองรับ เสียงแต่ละช่วงยาวไม่เกิน 30 วินาที เฉพาะระหว่างฝึกมีการสุ่มปรับระดับเสียงภายในช่วง 3 dB และเติมสัญญาณรบกวนที่อัตราส่วนสัญญาณต่อสัญญาณรบกวน (SNR) 25--40 dB การฝึกแบบจับคู่เสียงกับข้อความใช้น้ำหนักฟังก์ชันสูญเสีย 0.05 และค่าอุณหภูมิ (temperature) 0.07 สำหรับการทดลอง 3 รอบ มีการกำหนดจำนวนรอบใหม่ในคำสั่ง โค้ดกำหนด seed ให้ Python, NumPy และ PyTorch แต่ไม่ได้บังคับให้ GPU คำนวณซ้ำแล้วได้ผลเหมือนเดิมทุกครั้ง

รายงานระบุชื่อโมเดลบน Hugging Face แต่ไม่มีรหัสรุ่นถาวรของน้ำหนัก (immutable revision) หากน้ำหนักต้นทางเปลี่ยน การดาวน์โหลดด้วยชื่อเดิมอาจได้คนละรุ่นกับที่เคยใช้ น้ำหนักที่ฝึกในโครงการเผยแพร่ที่ <https://huggingface.co/Thanabordee/AudioLaya-poc> ส่วนบันทึกการทดลองใน runs/ ไม่ได้รวมไว้ในชุดเผยแพร่

3.3.3 สภาพแวดล้อม คำสั่ง และผลลัพธ์

README ระบุให้ใช้ Python 3.10 ขึ้นไป ติดตั้ง PyTorch รุ่นที่รองรับฮาร์ดแวร์ก่อน แล้วจึงติดตั้งแพ็คเกจอื่นจาก requirements.txt ซึ่งกำหนดเพียงเวอร์ชันขั้นต่ำและไม่มีไฟล์ล็อกเวอร์ชัน (lockfile) สภาพแวดล้อมที่ตรวจสอบสำหรับรายงานนี้ใช้ Python 3.12.14, PyTorch 2.8.0+rocm7.1.0.lw.git7a520360, Transformers 5.17.0, NumPy 2.5.3 และ scikit-learn 1.9.1 แต่ไม่มีหลักฐานว่าการทดลองก่อนหน้านี้ทุกครั้งใช้เวอร์ชันเหล่านี้

ซอร์สโค้ดรุ่นที่เผยแพร่ติด tag **v1.0.2** และเก็บถาวรที่ <https://doi.org/10.5281/zenodo.22933883> ส่วนบันทึกการทดลองเดิมไม่ได้เก็บค่าใช้งานจริง รายการแพ็คเกจ รุ่นโมเดล และรุ่นซอร์สโค้ดครบทุกครั้ง คำสั่งด้านล่างใช้รันซ้ำได้ แต่ยังรับรองว่าจะได้ผลเหมือนเดิมทุกประการไม่ได้

ให้รันคำสั่งจากโฟลเดอร์หลักของโครงการ ส่วนต้นของคำสั่งจะดึงข้อมูล FTC และ Harper ตาม commit ที่ตรวจสอบไว้ โดยต้องติดตั้ง PyTorch ให้ตรงกับฮาร์ดแวร์ก่อนติดตั้งแพ็คเกจใน requirements.txt

```
python -m venv .venv
. .venv/bin/activate
# Install a hardware-matched PyTorch build in this environment first.
```

```

python -m pip install -r requirements.txt

git clone https://github.com/wspr-ncsu/robocall-audio-dataset.git data/raw/
ftc
git -C data/raw/ftc checkout 5aa6f3bfa8563ce8c1c75ebf8a2271e6ff6b4272
git clone \
    https://github.com/cricketclub/gridspace-stanford-harper-valley.git \
    data/raw/harper
git -C data/raw/harper checkout 0bd721e877c4a85d8c13ff837e68661ea6200a98
python -m src.data.prepare_ftc --root data/raw/ftc
python -m src.data.prepare_harper --root data/raw/harper

python -m src.train --experiment projector_only
python -m src.train --experiment projector_head
python -m src.evaluate --checkpoint runs/projector_only/best.pt \
    --out results/projector_only
python -m src.evaluate \
    --checkpoint runs/projector_head/best.pt --out results
python -m src.transcript_baseline

python -m src.train --experiment projector_only \
    --semantic-weight 0.05 --semantic-temperature 0.07 \
    --output-dir runs/projector_semantic
python -m src.semantic_eval \
    --checkpoint runs/projector_semantic/best.pt --split test
python -m src.train --experiment projector_only --epochs 3 \
    --semantic-weight 0.05 --semantic-temperature 0.07 \
    --output-dir runs/projector_semantic_3epochs
python -m src.semantic_eval \
    --checkpoint runs/projector_semantic_3epochs/best.pt --split test

python -m src.transfer_eval --task configs/transfer_minds14.json \
    --out results/transfer/minds14_zero_shot.json
python -m src.transfer_eval --task configs/transfer_urgency.json \
    --skip-gold-transcript --out results/transfer/urgency_zero_shot.json
python -m src.transfer_eval --task configs/transfer_minds14.json \
    --checkpoint-semantic runs/projector_semantic/best.pt \
    --skip-text-baselines \
    --out results/transfer/minds14_semantic_zero_shot.json
python -m src.transfer_eval --task configs/transfer_urgency.json \
    --checkpoint-semantic runs/projector_semantic/best.pt \
    --skip-text-baselines --skip-gold-transcript \
    --out results/transfer/urgency_semantic_zero_shot.json

```

```
python -m src.transfer_eval --task configs/transfer_minds14.json \
--checkpoint-semantic runs/projector_semantic_3epochs/best.pt \
--skip-text-baselines --out results/transfer/minds14_semantic_3epochs.json
python -m src.transfer_eval --task configs/transfer_urgency.json \
--checkpoint-semantic runs/projector_semantic_3epochs/best.pt \
--skip-text-baselines --skip-gold-transcript \
--out results/transfer/urgency_semantic_3epochs.json
python -m unittest discover -s tests
```

คำสั่งทดสอบงานใหม่ประเมินวิธี A และ B โดยปริยาย คำสั่งชุดแรกทดสอบวิธีที่ใช้ข้อความด้วย ส่วนคำสั่งที่ระบุน้ำหนักจากการฝึกจับคู่เสียงกับข้อความจะข้ามการทดสอบวิธีข้อความซ้ำ ผลการประเมินอยู่ใน results/ ส่วนน้ำหนักและบันทึกการฝึกบางส่วนอยู่ใน runs/ มีการบันทึกเวลารวมของการฝึกแบบจับคู่เสียงกับข้อความ 3 รอบไว้ที่ 492.11 วินาที ส่วนหน่วยความจำ GPU สูงสุดที่จัดสรรมีบันทึกทุกวิธีที่ฝึก เช่น 2,406,236,160 ไบต์สำหรับการฝึก 3 รอบ และ 2,390,304,768 ไบต์สำหรับวิธี A แต่ไม่มีบันทึกเวลาฝึกของวิธีอื่นที่เปรียบเทียบกันได้ หรือเวลารวมของโครงการ

3.3.4 สรุปตามรายการตรวจสอบ

รายการต่อไปนี้เป็นประเมินความครบถ้วนตามหัวข้อที่อ้างถึง ไม่ใช่คำรับรองสำหรับการส่งผลงานให้ NeurIPS

- **โค้ด ข้อมูล และคำสั่ง:** บางส่วน รหัสรุ่นที่ติดป้าย (tag v1.0.2) ซึ่งเก็บถาวรที่ <https://doi.org/10.5281/zenodo.22933883> มีสคริปต์ ไฟล์ตั้งค่า คำสั่งสำหรับรันซ้ำ และผลการทดลองที่เก็บไว้ แต่ไม่ได้เผยแพร่ไฟล์เสียงหรือข้อความถอดเสียง เนื่องจากชุดข้อมูลต้นทางมีเงื่อนไขการใช้ของตัวเอง โดย README อธิบายวิธีดาวน์โหลดและสร้าง manifest ใหม่ น้ำหนักโมเดลที่ฝึกแล้วเผยแพร่แยกที่ <https://huggingface.co/Thanabordee/AudioLaya-poc>
- **รายละเอียดการทดลอง:** บางส่วน ระบุวิธีแบ่งชุดข้อมูลและค่าการฝึกเริ่มต้น พร้อมทั้งไฟล์ตั้งค่าที่เผยแพร่จริง แต่โมเดลฐานอ้างด้วยชื่อ มิได้ระบุรหัสรุ่นที่แน่นอน และไม่มีบันทึกสภาพแวดล้อมที่ยืนยันได้ต่อการรันแต่ละครั้ง
- **นัยสำคัญทางสถิติ:** ยังไม่มี รายงานผลจากการทดลองครั้งเดียว โดยไม่มีการทดลองซ้ำด้วย seed ต่างกัน ช่วงความเชื่อมั่น หรือแถบค่าคลาดเคลื่อน
- **ทรัพยากรคำนวณ:** บางส่วน บันทึกเวลาไว้เฉพาะการฝึกแบบจับคู่เสียงกับข้อความ 3 รอบที่ 492.11 วินาที ส่วนหน่วยความจำสูงสุดมีบันทึกสำหรับวิธีที่ฝึกทุกวิธี แต่ไม่มีเวลาฝึกของวิธีอื่นที่เทียบกันได้ หรือเวลาคำนวณรวมของโครงการ
- **ทรัพยากรและใบอนุญาต:** บางส่วน ระบุที่มาและเงื่อนไขการใช้ชุดข้อมูลแล้ว และน้ำหนักที่เผยแพร่ใช้สัญญาอนุญาต MIT ของโครงการนี้ ส่วนโมเดลฐานยังอยู่ภายใต้เงื่อนไข Apache-2.0 ของตัวเอง

ข้อมูลที่เผยแพร่จึงช่วยให้ **รันการทดลองซ้ำได้บางส่วน** แต่ยังยืนยันว่าจะได้ผลตรงเดิมไม่ได้ เพราะรายงานผลจากการรันครั้งเดียว และไม่ได้ระบุรหัสรุ่นถาวรของโมเดลฐาน

บทที่ 4

ผลการทดลองและอภิปรายผล

4.1 ผลเชิงปริมาณ

4.1.1 ผลการจำแนกสายไม่พึงประสงค์และสายปกติ

วิธี A ฝึกเฉพาะชั้นแปลงมิติ ส่วนวิธี B ปรับส่วนตัดสินใจของ Laya ร่วมด้วย จำนวนพารามิเตอร์ที่ฝึกต่างกัน จึงไม่ใช้การเปรียบเทียบโดยควบคุมขนาดโมเดลให้เท่ากัน

ตารางที่ 4.1: ผลการจำแนกสายที่มีป้ายกำกับ spam และ legitimate บนชุดทดสอบเดียวกันจำนวน 282 สาย

วิธี	Macro F1	AUROC
A: ฝึกเฉพาะชั้นแปลงมิติ	99.6%	100.0%
B: ปรับชั้นแปลงมิติและส่วนตัดสินใจ	100.0%	100.0%
C: Whisper ASR → Laya	89.2%	94.9%
A + จับคู่เสียงกับข้อความ, 3 รอบ	99.6%	100.0%
A + จับคู่เสียงกับข้อความ, 10 รอบ	100.0%	100.0%

วิธีรับเสียงโดยตรงได้คะแนนสูงบนชุดทดสอบนี้ แต่เพราะแหล่งข้อมูลตรงกับป้ายกำกับทุกกรณี จึงยังสรุปไม่ได้ว่าโมเดลเรียนรู้ลักษณะของสาย spam ที่ใช้จำแนกเสียงจากแหล่งอื่นได้ เวลาอนุมานเฉลี่ยในการประเมินครั้งนี้คือ 55.3 มิลลิวินาทีต่อสายสำหรับ A, 70.9 มิลลิวินาทีสำหรับ B และ 762.3 มิลลิวินาทีสำหรับ C วิธีที่ถอดเสียงก่อนใช้เวลานานกว่าประมาณ 10.8–13.8 เท่า ตัวเลขเหล่านี้ขึ้นกับฮาร์ดแวร์และความยาวเสียง ไม่ใช่เกณฑ์เปรียบเทียบความเร็วของระบบอื่น

การทดสอบเพิ่มเติมกับสายบทสนทนาสมมติฝ่ายผู้ให้บริการ 14 สายจากชุด AppTek Call-Center Dialogues ซึ่งเก็บบันทึกไว้ที่ `results/external_apptek/abc_comparison.json` พบว่าทั้งสามวิธีไม่แจ้งเตือนผิดเลย แต่ตัวอย่างทั้ง 14 สายเป็นสายปกติและมีจำนวนน้อยเกินกว่าจะประมาณอัตราแจ้งเตือนผิด อีกทั้งไม่ได้เผยแพร่ไฟล์เสียง รายงานจึงไม่ใช่ผลนี้เป็นหลักฐานหลัก

4.1.2 ผลการจำแนกงานใหม่โดยไม่ฝึกเพิ่มเติม

บน MinDS-14 วิธีที่ใช้เสียงโดยตรงมีความแม่นยำใกล้เคียงหรือต่ำกว่าการทนายคลาสที่พบบ่อยที่สุด และมักทำนายเป็น `cash_deposit` ส่วนวิธี C ได้คะแนนสูงเพราะถอดเสียงก่อนให้ Laya จำแนกข้อความ ผลนี้สะท้อนประสิทธิภาพของกระบวนการ

ตารางที่ 4.2: ผลบนงานใหม่ วิธี C ใช้ข้อความถอดเสียง จึงรับข้อมูลต่างชนิดกับ A และ B

ชุดข้อมูล	วิธี	Accuracy	Macro F1	Macro AUROC (OvR)
MInDS-14	หายคลาสที่พบบ่อยที่สุด	8.5%	1.1%	---
	A: ฝึกเฉพาะชั้นแปลงมิติ	8.0%	1.4%	49.7%
	B: ปรับชั้นแปลงมิติและส่วนตัดสินใจ	6.2%	2.9%	49.0%
	A + จับคู่เสียงกับข้อความ, 10 รอบ	8.5%	2.0%	50.8%
	A + จับคู่เสียงกับข้อความ, 3 รอบ*	6.6%	1.6%	49.8%
	C: Whisper ASR → Laya	93.6%	93.7%	99.3%
	C: ข้อความถอดเสียงอ้างอิง → Laya	90.9%	91.1%	99.0%
ชุดเสียงเร่งด่วน (40 คลิป)	หายคลาสที่พบบ่อยที่สุด	50.0%	33.3%	---
	A: ฝึกเฉพาะชั้นแปลงมิติ	45.0%	43.7%	51.8%
	B: ปรับชั้นแปลงมิติและส่วนตัดสินใจ	72.5%	70.3%	99.8%
	A + จับคู่เสียงกับข้อความ, 10 รอบ	52.5%	44.7%	72.8%
	A + จับคู่เสียงกับข้อความ, 3 รอบ*	80.0%	80.0%	88.8%
	C: Whisper ASR → Laya	97.5%	97.5%	100.0%

ถอดเสียงแล้วจำแนกข้อความ ไม่ใช่ความสามารถของชั้นแปลงมิติในการจำแนกเจตนา 14 ประเภท การทดลองที่ให้ Laya รับข้อความถอดเสียงอ้างอิงเป็นการเปรียบเทียบเสริม ไม่ใช่วิธีที่รับเสียงแบบเดียวกับ A และ B

บนชุดเสียงเร่งด่วน วิธี B ได้ AUROC 99.8% แต่เมื่อใช้เกณฑ์ตัดสินเริ่มต้นกลับตรวจพบคลิปเร่งด่วนเพียง 9 จาก 20 คลิป วิธีที่ฝึกจับคู่เสียงกับข้อความ 10 รอบตรวจพบ 3 จาก 20 คลิป ส่วนวิธี 3 รอบตรวจพบ 16 จาก 20 คลิป แต่เลือกจำนวนรอบฝึกหลังพิจารณาผลบนคลิป 40 รายการชุดเดียวกันแล้ว จึงถือเป็นผลสำรวจ ไม่ใช่ผลทดสอบอิสระ วิธี C ตรวจพบ 19 จาก 20 คลิปโดยถอดเสียงก่อนให้ Laya ตัดสินใจ ผลทั้งหมดมีความไม่แน่นอนสูงเพราะตัวอย่างมีน้อย เป็นเสียงสังเคราะห์ และเนื้อหาที่พูดอาจบอกป้ายกำกับได้เอง


ภาพที่ 4.1 เปรียบเทียบความแม่นยำทั้งสามชุด งานจำแนกสายให้ผลของวิธีรับเสียงโดยตรงใกล้เคียงกับวิธีที่ถอดเสียงมากกว่า การทดสอบบน MInDS-14 ซึ่งวิธีรับเสียงโดยตรงได้คะแนนใกล้เคียงหรือต่ำกว่าการหายคลาสที่พบบ่อยที่สุด

4.1.3 ผลของการฝึกจับคู่เสียงกับข้อความ

ตารางที่ 4.3: ผลค้นคืนข้อความถอดเสียงจากตัวอย่างเสียง 445 รายการที่กันไว้จากชุดฝึก โดยเลือกจากข้อความ 413 รายการ หากสุ่มเลือก Recall@1 จะอยู่ที่ประมาณ 0.24%

แบบจำลองที่ประเมิน	ค่าฟังก์ชันสูญเสียในการค้นคืน	Recall@1	Recall@5
A ไม่ฝึกจับคู่	6.079	0.2%	1.1%
A ฝึกจับคู่ 3 รอบ	4.041	16.4%	52.1%
A ฝึกจับคู่ 10 รอบ	3.590	33.3%	74.8%

หลังฝึกด้วยฟังก์ชันสูญเสียแบบเปรียบเทียบ ระบบค้นคืนข้อความถอดเสียงที่คู่กับเสียงจาก FTC และ Harper ซึ่งกันไว้จากชุดฝึกได้ดีขึ้น แต่ส่วนตัดสินใจที่ใช้ฝึกจำแนก spam ยังไม่สามารถจำแนกเจตนาได้ดี วิธีที่ฝึกจับคู่เสียงกับข้อความ 10 รอบได้ Accuracy 8.5% และ Macro F1 2.0% บน MInDS-14 และได้ Accuracy 52.5% บนชุดเสียงเร่งด่วน การค้นคืนข้อความได้ดีขึ้นจึงยังไม่พอให้โมเดลตัดสินใจในงานใหม่ได้ถูกต้อง



รูปที่ 4.1: ความแม่นยำของทุกวิธีบนชุดประเมินสามชุด แยกตั้งแต่แสดงค่าตั้งแต่ 0 ถึง 1 วิธีที่รับเสียงโดยตรงได้คะแนนใกล้เคียงเพดานในงานจำแนกสาย แต่บน MinDS-14 มีความแม่นยำใกล้เคียงหรือต่ำกว่าค่าฐานจากการทายคลาสที่พบบ่อยที่สุด เส้นประแสดงค่าฐานของแต่ละชุด ลายกากบาทกับวิธี C ซึ่งรับข้อความถอดเสียง ไม่ใช่เสียงโดยตรง ส่วนลายเฉียงกับวิธีที่ฝึกจับคู่เสียงกับข้อความ ผลของวิธี 3 รอบบนชุดเสียงเร่งด่วนเป็นเพียงผลสำรวจ เพราะเลือกจำนวนรอบหลังเห็นผลบนคลิชุดเดิมแล้ว

4.2 การตีความผล

ผลบนชุดจำแนกสายแสดงว่าชั้นแปลงมิติส่งคุณลักษณะจาก Whisper ที่ตรงไ้ไปยังส่วนตัดสินใจของ Laya ได้ในงานนี้ วิธี A ฝึกพารามิเตอร์ 1.84 ล้านตัว และวิธี B ฝึก 28.09 ล้านตัว การฝึกแบบจับคู่เสียงกับข้อความ 3 รอบที่บันทึกเวลาไว้ใช้ประมาณ 8 นาทีบน AMD Radeon RX 9070 XT หนึ่งตัว ส่วนการนำแนวทางนี้ไปใช้กับข้อมูลชุดอื่นยังไม่ได้ทดสอบ

จำนวนพารามิเตอร์ที่ฝึกเพิ่มไม่ได้บอกขนาดระบบขณะใช้งาน เอกสารกำกับโมเดลระบุว่า Laya มีพารามิเตอร์ 421 ล้านตัว และระบบยังต้องใช้ตัวเข้ารหัส Whisper ด้วย การจำแนกงานใหม่จากเสียงโดยตรงได้ผลต่ำ ขณะที่คะแนนจำแนกสายหลักก็ยังแยกผลของแหล่งข้อมูลออกจากป้ายกำกับไม่ได้ จึงต้องทดสอบกับสายที่ป้ายกำกับไม่ขึ้นกับแหล่งข้อมูล และประเมินงานใหม่บนชุดทดสอบอิสระก่อนอ้างว่าใช้แนวทางนี้ได้กว้างขึ้น งานนี้ประเมินเพียงการเลือก spam หรือ legitimate เป็นหลัก อีกทั้งระบบเตือนว่าคะแนนยังไม่ผ่านการปรับเทียบ จึงไม่ควรใช้คะแนนที่โมเดลส่งออกเป็นค่าความเชื่อมั่น

บทที่ 5

ข้อจำกัด การใช้อย่างรับผิดชอบ และบทสรุป

5.1 ข้อจำกัดและการใช้อย่างรับผิดชอบ

การตีความผลมีข้อจำกัดดังนี้:

1. **แหล่งข้อมูลตรงกับป้ายกำกับ:** สาย spam ในชุดทดสอบมาจาก FTC ทั้งหมด ส่วนสาย legitimate มาจาก Harper ทั้งหมด ต้องทดสอบกับข้อมูลที่แต่ละแหล่งมีทั้งสองป้ายกำกับ และกับแหล่งเสียงที่โมเดลไม่เคยพบ
2. **ข้อจำกัดของชุดทดสอบงานใหม่:** MinDS-14 รุ่นที่ใช้ไม่มีชุดทดสอบแยกอย่างเป็นทางการ ชุดเสียงเร่งด่วนมีเสียงสังเคราะห์เพียง 40 คลิป และวิธี 3 รอบเลือกจำนวนรอบหลังเห็นผลบนคลิปชุดเดียวกัน
3. **ข้อมูลเข้าต่างชนิดกัน:** A และ B รับเสียงโดยตรง ส่วน C ถอดเสียงก่อนให้ Laya จำแนกข้อความ คะแนนจึงไม่ใช่ผลเปรียบเทียบภายใต้ข้อมูลเข้าแบบเดียวกัน
4. **ความสามารถเดิมของ Laya:** Laya ผ่านการฝึกกับข้อความมาก่อน งานนี้ไม่ได้แยกผลของการเชื่อมเสียงออกจากความสามารถในการตัดสินใจที่โมเดลมีอยู่แล้ว
5. **ขนาดและต้นทุนระบบ:** จำนวนพารามิเตอร์ที่ฝึกเพิ่มและเวลาจากการรันครั้งเดียวไม่ได้บอกขนาด หน่วยความจำพลังงาน หรือต้นทุนของระบบทั้งหมด ไม่มีเวลาฝึก 10 รอบที่เทียบกันได้ และเวลาอนุมานขึ้นกับฮาร์ดแวร์กับความยาวเสียง
6. **ความไม่แน่นอนของผล:** แต่ละวิธีมีผลจากการรันครั้งเดียว ไม่มีการทดลองซ้ำด้วย seed ต่างกันหรือช่วงความเชื่อมั่น วิธี B ฝึกพารามิเตอร์มากกว่า A ประมาณ 15 เท่า จึงไม่ใช่การเปรียบเทียบที่ควบคุมจำนวนพารามิเตอร์ให้เท่ากัน ความต่างของคะแนนเล็กน้อยยังสรุปนัยสำคัญทางสถิติไม่ได้
7. **ข้อมูลการรันยังไม่ครบ:** ไม่มีรหัสรุ่นถาวรของน้ำหนักโมเดลฐานหรือไฟล์ล็อกเวอร์ชันแพ็คเกจ บันทึกการรันเดิมก็ไม่ได้เก็บรุ่นซอร์สโค้ด สภาพแวดล้อม และค่าตั้งจริงอย่างครบถ้วน จึงรับรองผลซ้ำที่ตรงกันทุกประการไม่ได้
8. **ยังไม่ทดสอบข้อมูลชนิดอื่น:** รายงานนี้ไม่มีผลจากภาพ วิดีโอ หรือเซนเซอร์

9. **ยังไม่พร้อมใช้งานจริง:** ระบบเป็นต้นแบบวิจัย ไม่ใช่ระบบล็อกสายที่ผ่านการตรวจสอบ ไม่ควรนำคะแนนที่ยังไม่ปรับเทียบไปใช้ตัดสินใจเรื่องสำคัญโดยไม่มีการทดสอบอิสระ กำหนดเกณฑ์ตัดสิน และวิเคราะห์ความผิดพลาด

งานต่อไปควรใช้เสียงและข้อความถอดเสียงที่หลากหลายทั้งผู้พูด สำเนียง เนื้อหา และสภาพการบันทึก โดยกันผู้พูดและบางคลังข้อมูลไว้สำหรับทดสอบ ควรประเมินส่วนตัดสินใจกับงานที่มีป้ายกำกับอิสระ และไม่ใช้ผลจากชุดทดสอบสุดท้ายเลือกน้ำหนักโมเดลหรือจำนวนรอบฝึก งานจำแนกความเร่งด่วนต้องทดสอบกับเสียงคนจริง และกำหนดต้นทุนของการแจ้งเตือนผิดกับการพลาดเหตุเร่งด่วนก่อนพิจารณาใช้งาน ข้อมูลชนิดอื่นต้องทดลองต่างหาก

5.2 สรุป

การทดลอง Audio-Laya แสดงว่าสามารถฝึกขึ้นแปลงมิติให้ส่งคุณลักษณะจาก Whisper ที่จริงไว้ไปยัง Laya เพื่อจำแนกสายบนชุดทดสอบที่ใช้ได้ แต่คะแนนสูงบนชุดนี้ยังยืนยันการจำแนกสายจากคลังข้อมูลอื่นไม่ได้ เพราะแหล่งข้อมูลตรงกับป้ายกำกับทุกกรณี การฝึกจับคู่เสียงกับข้อความช่วยให้ค้นคืนข้อความถอดเสียงได้ดีขึ้น แต่ความแม่นยำในการจำแนกเจตนาจากเสียงโดยตรงบน MinDS-14 ยังใกล้เคียงการทายคลาสที่พบบ่อยที่สุด ขั้นตอนต่อไปคือทดสอบกับสายจากหลายแหล่งที่แต่ละแหล่งมีทั้งสองป้ายกำกับ และประเมินงานใหม่ด้วยชุดทดสอบอิสระ

เอกสารอ้างอิง

- [1] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, "Robust Speech Recognition via Large-Scale Weak Supervision," in *Proceedings of the 40th International Conference on Machine Learning*, vol. 202, pp. 28492–28518, 2023. <https://proceedings.mlr.press/v202/radford23a.html>
- [2] Convai Innovations, "Laya: typed-decision model," model card, Hugging Face. <https://huggingface.co/convaiinnovations/laya>. เข้าถึง กันยายน 2026.
- [3] S. Prasad and B. Reaves, "Robocall Audio from the FTC's Project Point of No Entry," North Carolina State University, Technical Report TR-2023-1, 2023. <https://www.csc2.ncsu.edu/techreports/tech/2023/TR-2023-1.pdf>
- [4] M. Wu, J. Nafziger, A. Scodary, and A. Maas, "HarperValleyBank: A Domain-Specific Spoken Dialog Corpus," arXiv:2010.13929, 2020. <https://arxiv.org/abs/2010.13929>
- [5] D. Gerz et al., "Multilingual and Cross-Lingual Intent Detection from Spoken Data," in *Proceedings of EMNLP*, 2021. <https://doi.org/10.18653/v1/2021.emnlp-main.591>
- [6] PolyAI, "MInDS-14 dataset," Hugging Face Datasets, CC BY 4.0. <https://huggingface.co/datasets/PolyAI/minds14>
- [7] S. Pinna, F. M. Mallocci, M. Marras, D. Reforgiato Recupero, D. Riboni, and G. Scarpi, "Multilingual speech dataset with urgency tone annotation," Zenodo, version 1, 2025. doi:10.5281/zenodo.17502378.
- [8] NeurIPS, "Paper Checklist Guidelines," 2026. <https://neurips.cc/public/guides/PaperChecklist>. Accessed September 2026.